دانشگاه تهران

پردیس فارابی

دانشکده مهندسی

گروه مهندسی کامپیوتر

پیاده سازی سیستمی برای تشخیص کلمات کلیدی فارسی در صوت با استفاده از متد های یادگیری عمیق

نگارش:

سیدسینا موسوی ثابت

استاد راهنما:

دکتر زهرا موحدی

گزارش پروژه برای دریافت درجه ی کارشناسی در رشته مهندسی کامپیوتر

شهریور 1401


بسم الله الرحمن الرحيم

چکیده

دستیارهای صوتی نرم‌افزار هوشمندی هستند که به دستورات صوتی پاسخ می‌دهند و می‌توانند بر روی هر دستگاهی از جمله تلفن‌های هوشمند، بلندگوها، رایانه‌های رومیزی/لپ‌تاپ، تبلت‌ها، ابزارهای پوشیدنی، کنسول‌های بازی، کنسول‌های تلویزیون، هدست‌های واقعیت مجازی (VR)، اتومبیل‌ها و دستگاه های اینترنت اشیا اجرا شوند. دستگاه های (IoT) به عنوان مثال می توان به الکسای آمازون، سیری اپل، دستیار گوگل و کورتانای مایکروسافت اشاره کرد.

در این پروژه، با استفاده از دیتاست های موجود در اینترنت و جمع آوری دیتا و استخراج ویژگی های مورد نیاز از سیگنال های صوتی و استفاده از مدل های یادگیری عمیق CNN و RNN، مدلی برای تشخیص کلمات کلیدی در صوت را ایجاد کردیم که قادر به تشخیص کلمات و مشخص کردن محل رخ داد آن در صوت میباشد. هدف از انجام این پروژه پیاده سازی یک دستیار صوتی زبان فارسی با استفاده از منابع موجود در اینترنت بود.

که در نتیجه کار یک برنامه ی دسکتاپ برای نمایش گرافیکی صوت و رابط کاربری گرافیکی پیاده سازی شد.

کلمات کلیدی: بازشناسی الگو، پردازش گفتار، یادگیری عمیق، سیگنال صوتی، CNN، RNN، برنامه دسکتاپ

فهرست

فصل اول

1-1 مقدمه

چگونه یک دستیار صوتی می تواند حرف ما را بفهمد؟ خوب، آنها بر اساس سیستم ASR (تشخیص خودکار گفتار) هستند.

ابتدا این سیستم‌ها گفتار را ضبط می‌کنند و سپس آن را به صداها یا گروه‌هایی از آنها (واج) که به متن ترجمه می‌شوند، تجزیه می‌کنند. دستیار همچنین می تواند لحن، فرکانس و صدها جنبه دیگر از صدای یک فرد را تجزیه و تحلیل و «به خاطر بسپارد» تا دقیقاً بداند چه کسی با آن صحبت می کند.

دستیار صوتی زمانی شروع به کار می کند که کاربر آن را با یک کلمه بیدار فعال کند. کاربران آمازون الکسا این نام را برای فعال کردن دستیار صوتی می گویند، در حالی که کاربران اپل می توانند برای انجام همین کار، "Hey Siri" را بگویند.

بنابراین، برای مثال، می‌توانید از سیری در آیفون خود بپرسید: «سیری، امروز هوا چگونه است؟». هنگامی که دستگاه بیدار می شود و سؤال شما را به فرمان ماشینی ترجمه می کند، اطلاعات را از اینترنت یا یک برنامه کاربردی برای یافتن پاسخ بازیابی می کند - در این مورد، پیش بینی آب و هوای آن روز را به صورت آنلاین ارائه می دهد.

با این حال، استفاده از هوش مصنوعی و به ویژه یادگیری ماشینی است که به دستیارهای صوتی این امکان را می دهد که با گذشت زمان هوشمندتر شوند. به لطف این فناوری‌ها، برنامه‌های دستیار صوتی مدرن دیگر نیازی به تکیه بر واژگان از پیش نصب شده محدود ندارند، بلکه می‌توانند به میلیون‌ها کلمه و عبارت در فضای ابری دسترسی داشته باشند. به لطف الگوریتم‌های یادگیری ماشینی، دستیارهای صوتی همچنین می‌توانند به یک سخنرانی کامل گوش دهند تا متن را به جای هر کلمه به طور جداگانه درک کنند.

هدف این پروژه ایجاد سیستمی برای تشخیص کلمات کلیدی مشخصی در صوت میباشد که شامل گام های زیر برای انجام آن میشود:

1. جمع آوری داده ها – جمع آوری داده های خام موجود در اینترنت و جمع آوری آنها به صورت دستی
2. تبدیل داده های خام به داده های قابل استفاده – پاکسازی و استخراج بخش های مفید دیتاست ها و لیبل زدن آنها
3. پیش پردازش داده ها و ایجاد دیتاست – تبدیل داده ها به فرمت قابل استفاده برای مدل های یادگیری عمیق و جمع آوری آنها در یک دیتاست واحد برای سهولت در فاز train مدل
4. مشخص کردن معماری مدل ها – مشخص کردن جزئیات مدل ها
5. پیاده سازی مدل ها و train آنها
6. بهینه سازی عملکرد مدلها

7. استفاده از چند نخی برای کار با مدل در کنار برنامه اصلی
8. پیاده سازی برنامه دسکتاپ

در ادامه به مرور کارهای مشابه و شرح گام های بالا خواهیم پرداخت.

فصل دوم

2-1 مروری بر کارهای مشابه

در آینده نزدیک، انتظار می رود دستیارهای صوتی نیز نقش فعال تری را ایفا کنند. دستیاران به جای اینکه فقط منتظر دستورات کاربر باشند، اطلاعات مربوط به زمینه را جمع آوری می کنند و سپس با ارائه پیشنهادات مفید به کاربر، ابتکار عمل را بر عهده می گیرند.

ردیف	شماره مرجع	محتویات پژوهش
1	[1]	مروری بر روش ها و پیشرفت های یادگیری عمیق در زمینه ی پردازش صوت و بررسی تکنیک های به روز استفاده شده در دنیای واقعی
2	[2]	ارائه روش بهینه برای سنتز صوت و تبدیل متن به صوت با استفاده از روش های یادگیری عمیق و مدل های شبکه عصبی بازگشتی
3	[3]	ارائه مدلی برای تشخیص فعالیت صوتی و مکالمه در صوت و استخراج آن
4	[4]	استفاده از یک سیستم برای تشخیص دو زبان متفاوت انگلیسی و چینی با استفاده از یادگیری عمیق
5	[5]	تشخیص صدای گریه نوزاد توسط یادگیری عمیق

از دیگر موارد دیگر میتوان به دستیار های صوتی اشاره کرد. برای مثال دستیار صوتی شرکت آمازون که Alexa نام دارد و یا دستیار صوتی شرکت اپل که Siri نام دارد و یا دستیار صوتی گوگل که Google assistant نام دارد. این دستیارهای صوتی با توجه به دسترسی این شرکت ها به مقادیر حجیم دیتا عملکرد بسیار خوبی دارند و با داشتن یک مدل زبان انگلیسی، قابلیت پردازش بر روی گفتار را دارند و میتوانند دستورات کاربر را اجرا کنند و باعث سهولت استفاده تلفن های هوشمند میشوند. به زودی، دستیارهای صوتی همچنین می‌توانند با شناسایی یک صدا و تطبیق آن با یک کارت اعتباری یا حساب بانکی، خریدها را تأیید کنند. کاربران می توانند به سادگی با استفاده از دستورات صوتی هزینه سفارشات خود را پرداخت کنند - دستیار صوتی فقط از آنها می خواهد که پرداخت را تأیید کنند. از دیگر موارد استفاده از پردازش صوت میتوان به دستیار های صوتی برای افراد نابینا اشاره کرد که با خواندن اطلاعات روی صفحه نمایش تلفن همراه یا سیستم های خانگی با لحنی نزدیک به انسان، امکان استفاده از این محصولات را به این افراد میدهند. همه ی تنها بخش اندکی از پیشرفت های هوش مصنوعی و دستیارهای صوتی را نمایان می کند.

فصل سوم

3-1 شرح کلی سیستم

در این قسمت به شرح کلی سیستم و توضیح الگوریتم های مورد استفاده میپردازیم. در سیستم پیاده سازی شده این پروژه، داده های ورودی از طریق میکروفون یا بصورت فایل های صوتی به سیستم داده میشود و سپس یک سری اقدامات بر روی این داده ی ورودی انجام میگیرد تا این داده ها قابل استفاده توسط مدل های ما شوند. در این بخش ابتدا سیگنال صوتی به بخش هایی با اندازه مساوی تقسیم میشود (در این پروژه به قسمت های 1 ثانیه ای). این تقسیم بندی به صورتی انجام میشود که قسمت ها با هم اشتراک داشته باشند تا اگر کلمه ی مورد نظر مدل در این صوت گفته شده بود در این قسمت بندی از بین نرود و برای مثال نیمی از آن در یک قسمت و باقی آن در قسمت دیگر نیفتد. جلوتر در رابطه با روش دقیق این کار توضیحات تکمیلی خواهم آورد. بعد از این تقسیم بندی، ویژگی ها از این قسمت ها استخراج میشوند و آماده ی استفاده برای مدل ها میشوند. سپس این ویژگی های استخراج شده به عنوان ورودی به مدل داده میشود تا مدل پیشبینی را انجام دهد. پس از آن خروجی به کاربر به نمایش در آورده میشود. در انتها نیز به پیاده سازی این موارد در قالب یک اپ دسکتاپ خواهیم پرداخت.

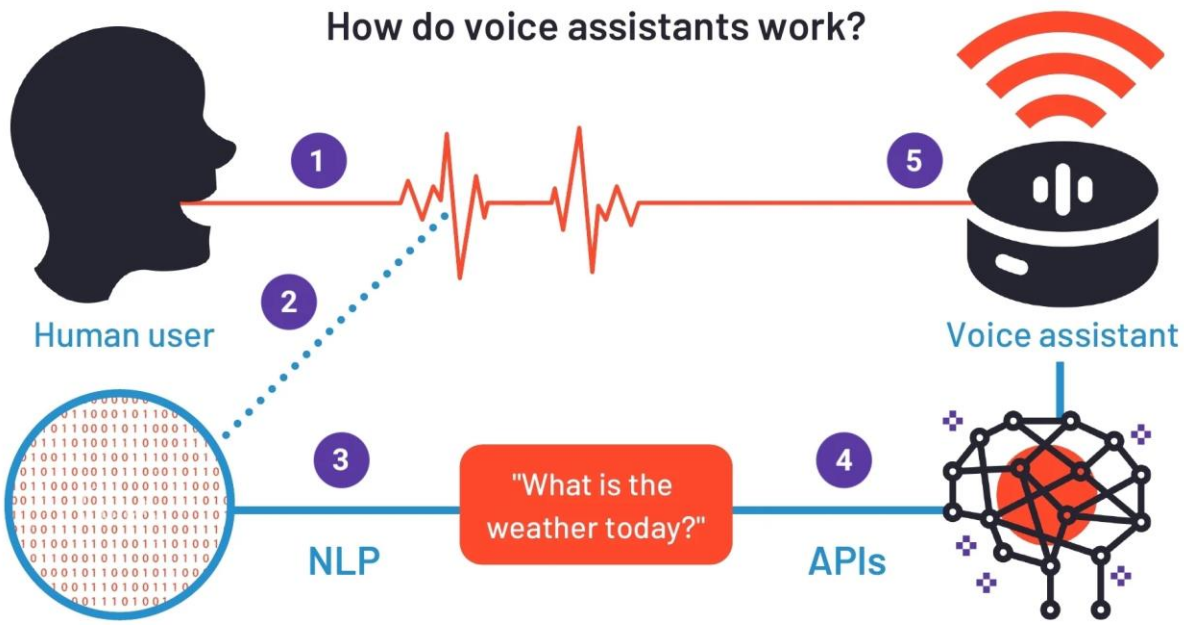

در فصل های بعدی به تفکیک و با جزئیات به فعالیت های انجام شده برای این پروژه خواهیم پرداخت. در ادامه کد های این پروژه و فصل مورد نظر آنها را مشاهده میکنید:

- کد app.py برای طراحی رابط کاربری گرافیکی. فصل 4
- کد real_time.py گرفتن صوت از ورودی میکروفون در حین اجرا و رسم نمودار و سپس فرستادن یک یک ثانیه ی صوت به model.py. فصل 4
- کد model.py برای ساخت مدل ها به منظور train کردن آنها . فصل 5

2-3 بررسی الگوریتم های یادگیری عمیق

در این بخش به بررسی الگوریتم های مختلف یادگیری عمیق و استفاده شده در این پروژه خواهیم پرداخت.

در این پروژه از الگوریتم های یادگیری عمیق برای ایجاد مدل ها استفاده شده. از جمله این مدل ها شبکه عصبی کانوولوشنال و شبکه عصبی بازگشتی هستند که در این پروژه مورد استفاده قرار گرفته اند.

یادگیری عمیق یک زیرشاخه از یادگیری ماشین و برمبنای مجموعه ای از الگوریتم ها است که در تلاشند تا مفاهیم انتزاعی سطح بالا در دادگان را مدل نمایند که این فرایند با استفاده از یک گراف عمیق که دارای چندین لایه پردازشی متشکل از چندین لایه تبدیلات خطی و غیرخطی هستند، مدل میکنند. انگیزه نخستین در به وجود آمدن این ساختار یادگیری از راه بررسی ساختار عصبی در مغز انسان الهام گرفته شده است که در آن یاخته های عصبی با فرستادن پیام به یکدیگر درک را امکان پذیر میکنند، بسته به فرض های گوناگون در مورد نحوه اتصال این یاخته های عصبی، مدل ها و ساختار های مختلفی در این حوزه پیشنهاد و بررسی شده اند، هرچند که این مدل ها به صورت طبیعی در مغز انسان وجود ندارد و مغز انسان پیچیدگی های بیشتری را داراست. از جمله این مدل ها میتوان به مدل های شبکه عصبی عمیق، شبکه عصبی کانوولوشنال و شبکه عصبی بازگشتی اشاره کرد.

3-2-1 شبکه های عصبی مصنوعی

یک شبکه عصبی یا شبکه عصبی عمیق (Artificial Neural Network) از یک لایه ورودی، یک لایه خروجی و چندین لایه ی پنهان میان این دو لایه تشکیل میشود. هر لایه از تعدادی نرون تشکیل شده است.

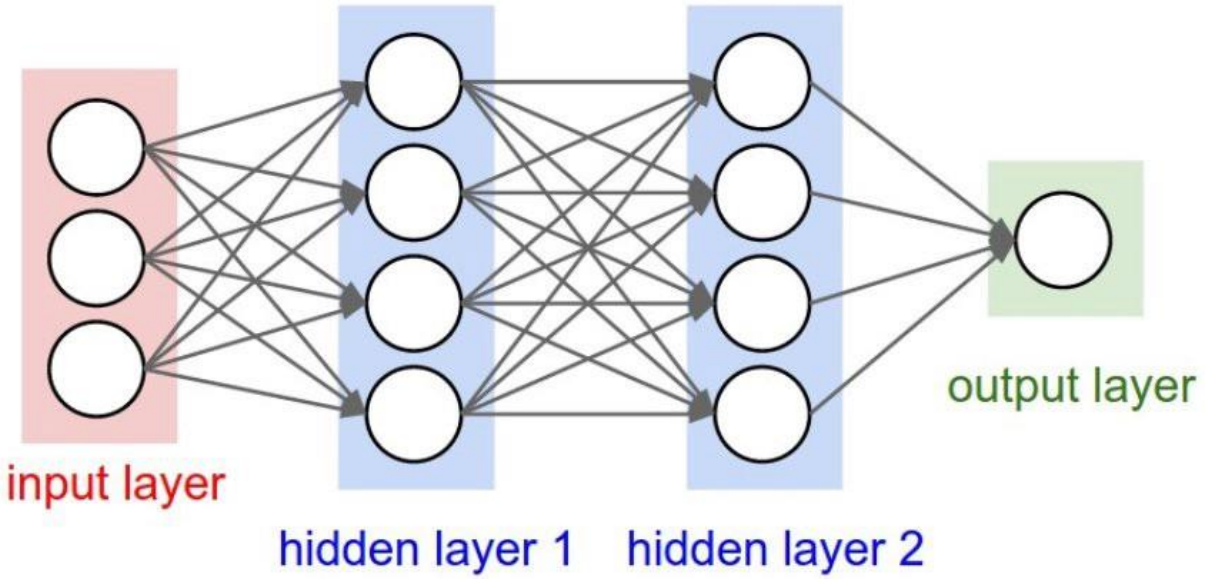

این نرون ها از بخش های مختلفی تشکیل شده است که این بخش ها شامل تابع فعال سازی غیرخطی و وزن ها بر روی اتصالات ورودی و خروجی آن در قالب یک تبدیل خطی میشود.

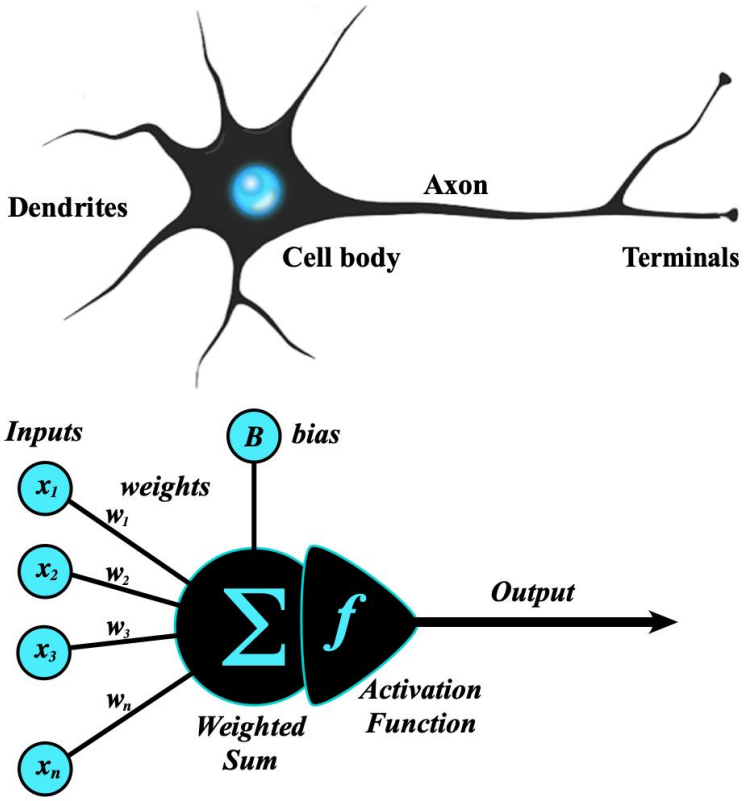

در این نرون یک بردار از وزن ها و یک مقدار bias نگهداری میشود که در نهایت پس از اعمال آنها روی ورودی های نرون، حاصل ها با یکدیگر جمع میشوند. این وزن ها اهمیت هر ورودی را نشان میدهند و تاثیر هر یک را روی خروجی این نرون مشخص میکنند. در پروسه ی آموزش شبکه عصبی مقادیر این وزن ها و bias تنظیم میشوند تا مدل به خروجی بهینه و مورد نظر برسد.

در فرمول زیر محاسبات انجام گرفته را مشاهده میکنید که خروجی این فرمول به عنوان ورودی به تابع فعالسازی داده میشود. در این فرمول یک مجموع وزن دار روی ورودی های نرون صورت میگیرد. این مجموع در نهایت با مقدار bias جمع میشود.

$$\sum_{j=1}^{n} x_j w_j$$

در ادامه به بررسی توابع فعالسازی میپردازیم. استفاده از این توابع غیرخطی برای بازنمایی های پیچیده و الگو های پیچیده داده ها لازم است چراکه بدون استفاده از این تابع ها تمامی نرون ها یک تبدیل خطی روی داده ها اعمال میکنند و کل شبکه به یک ترکیب خطی از ورودی ها تبدیل میشود و عملا تنها الگوهای ساده و خطی قابل استخراج میشوند. این توابع مانند نرون های مغز فعال میشوند و اتصال خود را با نرون بعدی برقرار میکنند. از توابع فعالسازی متداول که در شبکه های عصبی مورد استفاده قرار میگیرند میتوان به ReLu، leaky ReLu، tanh، sigmoid، softmax اشاره کرد که در ادامه به معرفی هر یک از آنها میپردازیم.

- **تابع فعالسازی ReLU** – تابع Rectified Linear Unit activation function یا به اختصار ReLU تابعی ست با نمودار و فرمول زیر:

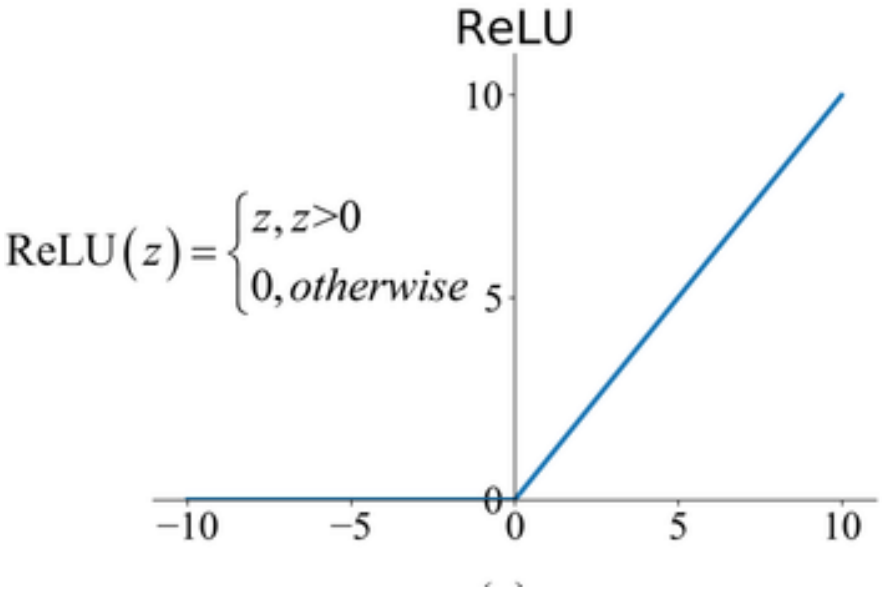

که خروجی آن برای ورودی های بزرگتر از 0 برابر با همان ورودی است. این تابع متداول ترین تابع در شبکه های عصبی میباشد چراکه فرایند آموزش با این تابع سریعتر هست. این تابع از نظر محاسباتی نیز بسیار کارامد است و سرعت همگرایی بالایی دارد.این تابع مشکل مرگ نرون را دارد که در مقادیر ورودی نزدیک صفر گرادیان تابع صفر میشود و در آموزش تاثیر میگذارد.

- **تابع فعالسازی tanh –** تابع تانژانت هایپربولیک تابعی است با فرمول و نمودار زیر:

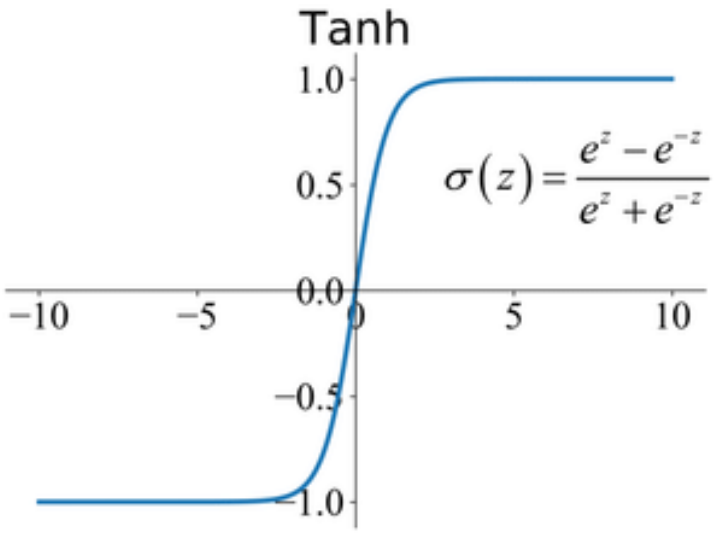

که در آن خروجی بین 1 و 1- بسته به مقدار ورودی تغییر میکند. این تابع مشکل محوشدگی گرادیان را دارد به این معنی که در مقادیر بسیار بزرگ یا کوچک ورودی، مشتق بسیار کوچک میشود و به آموزش شبکه لطمه میزند. این تابع به همین دلیل به کندی همگرا میشود و فرایند آموزش شبکه را طولانی میکند.

- **تابع فعالسازی Sigmoid** – تابعی با فرمول و نمودار زیر:

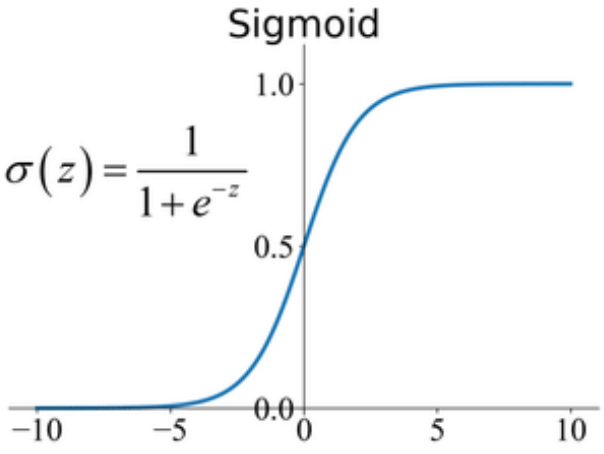

این تابع یک منحنی S شکل است. زمانی‌که می‌خواهیم خروجی مدل احتمال باشد، از تابع سیگموید استفاده می‌کنیم. چون تابع سیگموید مقادیر را به بازه صفر تا ۱ می‌برد و احتمالات هم میان همین بازه قرار دارند. این تابع هم مشکل محوشدگی گرادیان و هم گرایی کند را دارد.

- **تابع leaky ReLU** – تابعی با فرمول و نمودار زیر:

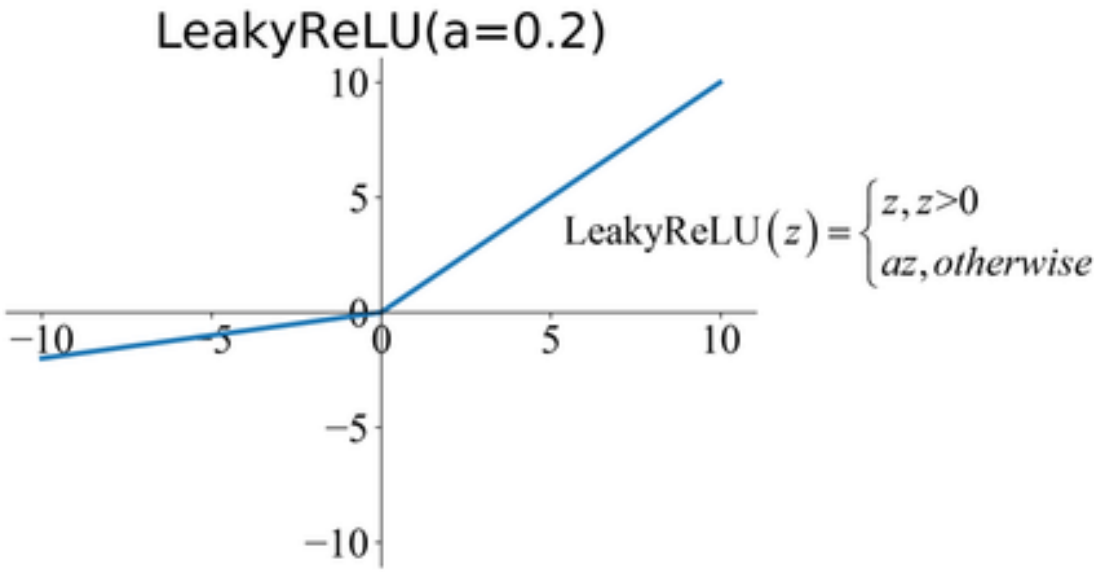

انتخاب تابع فعالسازی برای نرون ها به نوع مسئله مرتبط میباشد و هر کدام را میتوان با توجه به شرایط استفاده کرد. نکات زیر معمولا را میتوان در رابطه با این توابع فعالسازی بیان کرد:

- تابع سیگموید در مسائل کلاس بندی معمولا به خوبی عمل میکند.
- توابع سیگموید و tanh به دلیل مشکل محوشدگی گرادیان، در برخی موارد استفاده نمیشوند.

- در بیشتر مواقع از تابع ReLU استفاده میشود که این تابع نتایج خوبی را ارائه میکند.
- تابع ReLU تنها در لایه های پنهان مورد استفاده قرار میگیرد چرا که مقدار آن تا بینهایت میرود و ما در خروجی معمولا به یک احتمال یا یک مقدار کراندار نیاز داریم.
- در مواجهه با مشکل مرگ نرون میتوان از تابع leaky ReLU استفاده کرد.

فرایند آموزش شبکه عصبی

فرایند آموزش یا training process به تنظیم کردن وزن های هر نرون برای مینیمم کردن خطای مدل گفته میشود. در این فرایند با استفاده از یک تابع خطا، خطای مدل در پیشبینی خروجی با توجه به مجموعه ورودی های مدل (مجموعه داده های آموزش یا training data) محاسبه میشود و با توجه به این خطا وزن ها تنظیم میشوند. یکی از روش هایی که برای اینکار وجود دارد روش پس انتشار خطا یا back propagation of error نام دارد. در این روش دو مرحله وجود دارد که در مرحله ی اول که حرکت رو به جلو یا feed forward نام دارد، داده های ورودی از لایه ی ورودی به شبکه داده میشوند و این داده ها به سمت لایه خروجی رفته و عملیات هر نرون روی آنها اعمال میشود (مجموع وزن دار و توابع فعالسازی). سرانجام پس از این مرحله یک خروجی بدست میاید که این خروجی مقداری خطا نسبت به خروجی واقعی

دارد. اینجا مقدار خطا توسط تابع خطا محاسبه میشود و وارد مرحله دوم میشود. در این مرحله که انتشار رو به عقب یا back propagation نام دارد، وزن ها به هنگام سازی میشوند. این به هنگام سازی با توجه به مقدار تابع خطا صورت میگیرد تا در تکرار های بعدی این عملیات خطای کمتری داشته باشیم. در نهایت هدف رسیدن به کمترین مقدار خطا میباشد. در مرحله دوم این روش از مقدار خطا شروع به بازگشت به عقب میکنیم تا به لایه ورودی برسیم. در این مسیر مقدار گرادیان ها را محاسبه میکنیم و با داشتن مقدار خطا، سعی در مینیمم کردن مقدار خطا میکنیم. برای اینکار میتوان از روش کاهش گرادیان یا Gradient Descent استفاده کرد که در این روش با محاسبه ی گرادیان تابع خطا وزن ها را بهینه سازی میکند تا مقدار تابع خطا به مقدار مینیمم آن نزدیک شود.

توابع خطا یا توابع زیان (loss function) مختلفی برای استفاده در شبکه های عصبی وجود دارند که میتوان چند نمونه از آن ها را در ادامه مشاهده کرد (در فرمول هایی که در ادامه آورده شده است، $\hat{y}$ نشان دهنده ی مقدار پیشبینی شده توسط شبکه و y نشان دهنده ی مقدار واقعی خروجی میباشد)

- **تابع Means Square Error** – یکی از متداول ترین توابع مورد استفاده در شبکه های عصبی که برای مسائل رگرسیون هستند. این تابع میانگین مربعات خطا نسبت به مقدار واقعی را محاسبه میکند. فرمول این تابع به صورت زیر میباشد:

$$MSE = \frac{\sum(y_i - \hat{y}_i)^2}{n}$$

- **تابع Mean Absolute Error** – از این تابع نیز در مسائل رگرسیون استفاده میشود. این تابع میانگین قدرمطلق تفاضل بین مقدار پیشبینی شده و مقدار واقعی را محاسبه میکند. فرمول این تابع به صورت زیر میباشد:

$$MAE = \frac{\sum |y_i - \hat{y}_i|}{n}$$

- **تابع Binary Cross-entropy** – از این تابع در مسائل کلاس بندی با دو کلاس استفاده میشود. فرمول این تابع به صورت زیر میباشد:

$$-\frac{1}{\text{output size}} \sum_{i=1}^{\text{output size}} y_i \cdot \log \hat{y}_i + (1 - y_i) \cdot \log (1 - \hat{y}_i)$$

در نهایت با استفاده از این توابع مقدار کلی خطا برای تمامی داده های آموزش با میانگین گیری روی تمام خطا ها محاسبه میشود.

در نهایت با استفاده از روش گرادیان کاهشی و تکرار بر روی داده های آموزش، مقادیر وزن ها برای مینیمم سازی میزان خطا بهینه میشوند تا مدل با خطای کمی خروجی را پیشبینی کند.

3-2-2 شبکه های عصبی کانوولوشنال

یکی از مدل های رایج شبکه های عصبی عمیق، شبکه عصبی کانوولوشنال یا Convolutional Neural Network یا به اختصار CNN میباشد. این نوع شبکه عصبی برای پردازش تصویر بسیار مناسب میباشد و این شبکه ها یک بازنمایی پیچیده از داده های تصویری را با استفاده از مقدار حجیمی از داده ها یاد میگیرند. این شبکه ها از سیستم بینایی انسان الهام گرفته شده اند و چندین لایه از تبدیلات را یاد میگیرند. این شبکه ها از دو نوع لایه تشکیل میشوند که به شرح زیر میباشند:

- **لایه کانوولوشن** – این لایه با توجه به اینکه در تصاویر پیکسل ها در کنار هم معنا دار هستند و تک به تک معنایی ندارند و یک locality بین آنها برقرار است، با عملیات کانوولوشن بر روی آنها، ویژگی ها را استخراج میکند.

- **لایه تلفیق** – در این لایه ماکزیمم یا متوسط ویژگی ها بر روی یک ناحیه خاص محاسبه میشوند تا اندازه ی تصویر کاهش یابد و محاسبات در لایه های بعدی سبک تر شود.

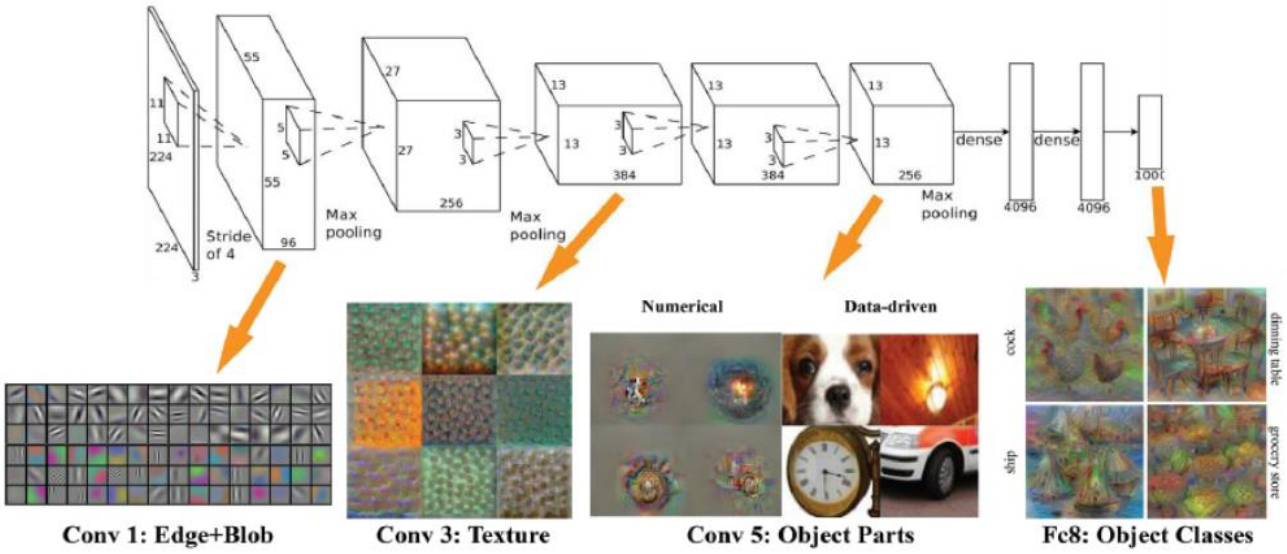

هر لایه ی کانوولوشن از تعدادی فیلتر تشکیل شده است که هر یک از این فیلتر ها به صورت یک ماتریس دوبعدی از اعداد هستند که در اصل معادل با وزن ها در شبکه عصبی مصنوعی عمل میکنند و در نهایت هدف تنظیم این مقادیر برای بهینه سازی عملکرد شبکه میباشد.

عملیات کانوولوشن:

در این عملیات یک ماتریس دوبعدی به عنوان فیلتر بر روی مقادیر پیکسل های تصویر (که خود نیز یک ماتریس دوبعدی میباشد) اعمال میشود. این عملیات سبب میشود تا به جای یادگیری یک وزن به ازای هر پیکسل از تصویر، با

یادگیری وزن های فیلتر به عملکردی بهتر و بهینه تر از نظر محاسباتی رسید. در تصویر زیر میتوان نحوه ی عملکرد این عملیات را مشاهده کرد:

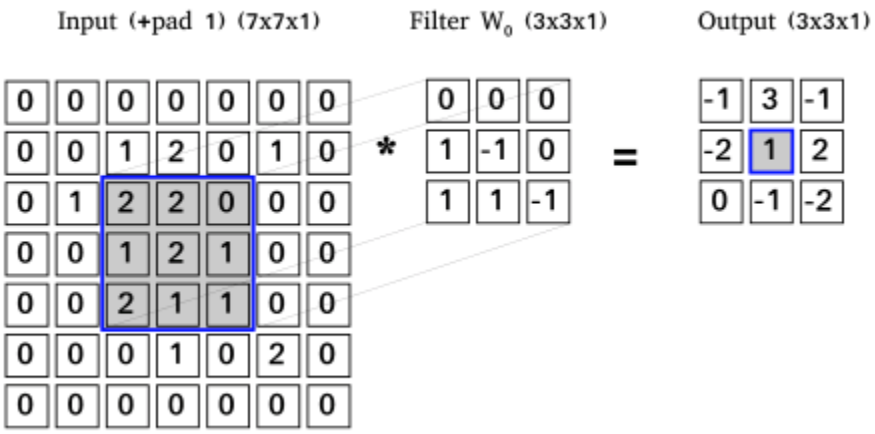

در تصویر بالا مربع بزرگ مقادیر تصویر و مربع کوچک وسطی مقادیر فیلتر را نشان میدهند. در هر مرحله فیلتر بر روی بخشی از تصویر اعمال میشود و خروجی آن بخش که یک عدد میباشد را در ماتریس خروجی قرار میدهد. این فیلتر با یک گام مشخص (برای مثال دو پیکسل دو پیکسل) روی تصویر حرکت میکند تا تمامی بخش های تصویر را پوشش دهد. نحوه ی محاسبات به این صورت میباشد که هر درایه از ماتریس در درایه متناظر با آن در فیلتر ضرب میشود و در نهایت نتیجه ی تمامی این ها با هم جمع شده و به عنوان خروجی در نظر گرفته میشود. برای مثال برای تصویر بالا داریم:

$$2x0 + 2x0 + 0x0 + 1x1 + 2x-1 + 1x0 + 2x1 + 1x1 + 1x-1 = 1$$

پس از این که خروجی عملیات کانوولوشن در لایه کانوولوشن مشخص شد این ماتریس با ماتریس bias جمع شده و نتیجه آن به یک تابع فعالسازی داده

میشود و خروجی این تابع فعالسازی به عنوان ورودی لایه بعدی در نظر گرفته میشود.

عملیات تلفیق:

از این عملیات برای کاهش ابعاد بازنمایی ها استفاده میشود. روش های مختلفی برای این عملیات وجود دارد که در ادامه به آنها میپردازیم.

- Max-Pooling – در این روش هر فیلتر با یک گام مشخص بر روی تصویر حرکت میکند و هر بار مقدار ماکزیمم را به عنوان خروجی باز میگرداند. فرمول آن به صورت زیر میباشد:

$$h_i^n(r,c) = \max_{\bar{r}\in N(r),\ \bar{c}\in N(c)} h_i^{n-1}(\bar{r},\bar{c})$$

در تصویر زیر میتوان اعمال این عملیات بر یک ماتریس را مشاهده کرد:

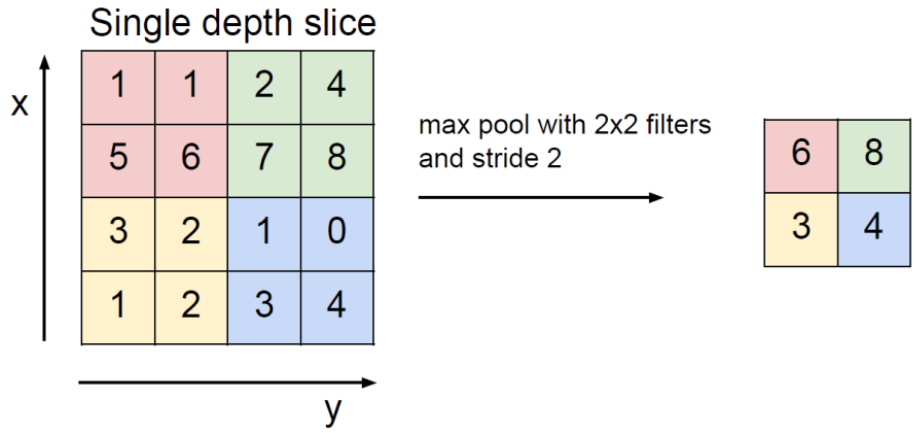

در تصویر بالا یک فیلتر 2 max-pool در 2 با اندازه گام 2 بر روی تصویر اعمال شده که خروجی به صورت ماتریس سمت راست میشود.

- Average-Pooling – در این روش هر فیلتر با یک گام مشخص بر روی تصویر حرکت میکند و هر بار مقدار میانگین را به عنوان خروجی باز میگرداند. فرمول آن به صورت زیر میباشد:

$$h_i^n(r,c) = \underset{\bar{r}\in N(r),\ \bar{c}\in N(c)}{\text{mean}} \quad h_i^{n-1}(\bar{r},\bar{c})$$

در تصویر زیر میتوان اعمال این عملیات بر روی یک ماتریس مشاهده کرد:

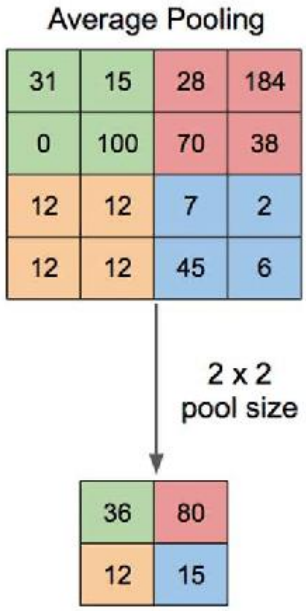

در تصویر بالا یک فیلتر 2 average-pool در 2 با اندازه گام 2 بر روی تصویر اعمال شده که خروجی به صورت ماتریس پایینی میشود.

این دو روش از متداول ترین روش ها میباشند و معمولا از یکی از این دو روش در شبکه های کانوولوشنال استفاده میشود.

پس از لایه های کانوولوشن و تلفیق، برای بدست آوردن خروجی که به صورت تک عدد میباشد، نمیتوان از فیلتر ها که خروجیشان ماتریسی از اعداد است استفاده کرد و در لایه های اخر شبکه های کانوولوشنال از یک لایه ی تماما متصل (Fully Connected Layer) استفاده میشود. ورودی این لایه تخت شده ی ماتریس خروجی اخرین لایه ی کانوولوشن یا تلفیقی (بسته به معماری شبکه) میباشد. به این معنا که ماتریس دوبعدی خروجی لایه قبل به یک آرایه تک بعدی تبدیل میشود و این آرایه به عنوان ورودی به این لایه داده میشود. این لایه همانند لایه پنهان در شبکه عصبی مصنوعی میباشد و هر نرون آن یک وزن و یک bias دارد. در شبکه های کانوولوشنال معمولا چندین لایه ی آخر شبکه لایه های Fully Connected میباشند که در لایه ی خروجی با توجه به نوع مسئله تابع فعالسازی مناسب انتخاب میشود. در تصویر زیر یک نمونه از شبکه عصبی کانوولوشنال را مشاهده میکنید:

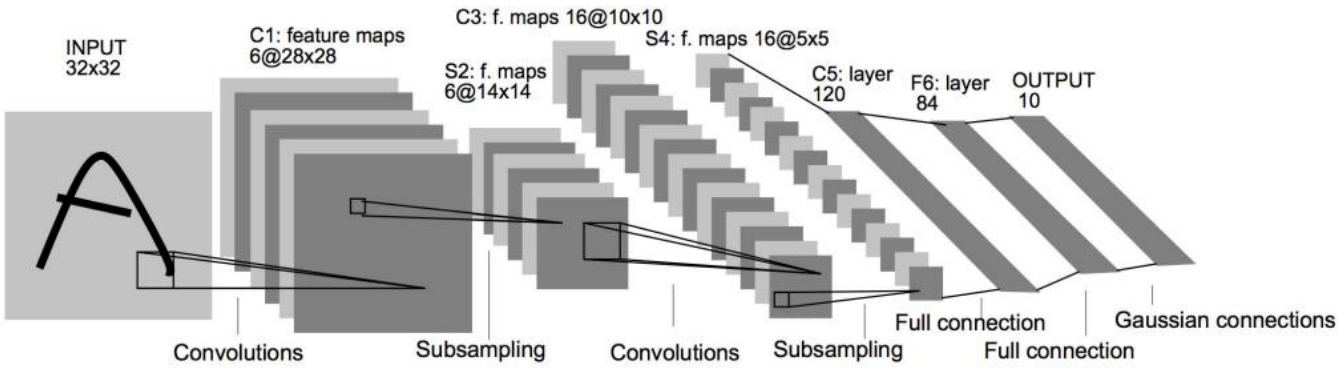

3-2-3 شبکه های عصبی بازگشتی

شبکه عصبی بازگشتی Recurrent Neural Network یا به اختصار RNN نوعی از شبکه های عصبی میباشند که در تشخیص گفتار، پردازش زبان طبیعی، پردازش صوت و به صورت کلی پردازش داده های ترتیبی (Sequential data) استفاده میشود. در این شبکه ها برخلاف شبکه های معرفی شده تا اینجا، یک لایه ی بازخورد داریم که خروجی شبکه به همراه ورودی بعدی به شبکه بازگرداننده میشود. ای شبکه ها با استفاده از این مکانیزم دارای حافظه داخلی میباشند و میتوانند ورودی های قبلی را به خاطر بسپارند و از این حافظه برای پردازش دنباله ای از ورودی ها بهره ببرند.

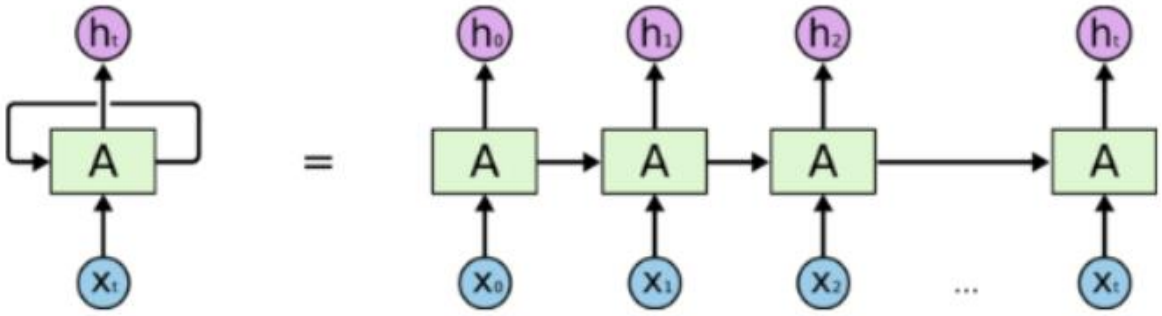

An unrolled recurrent neural network.

در تصویر بالا یم لایه از شبکه عصبی بازگشتی را مشاهده میکنید که در اصل یک واحد میباشد که از خروجی زمان t-1 در زمان t به عنوان ورودی استفاده میکند و با استفاده از مکانیزم هایی میتواند اطلاعاتی از زمان های قبل تر هم نگه دارد.

معماری های مختلفی از این شبکه وجود دارد که میتوان به نمونه های زیر اشاره کرد:

- Many-to-many در این معماری هم ورودی و هم خروجی یک دنباله میباشند. از موارد استفاده این معماری میتوان به ترجمه ماشینی اشاره کرد.

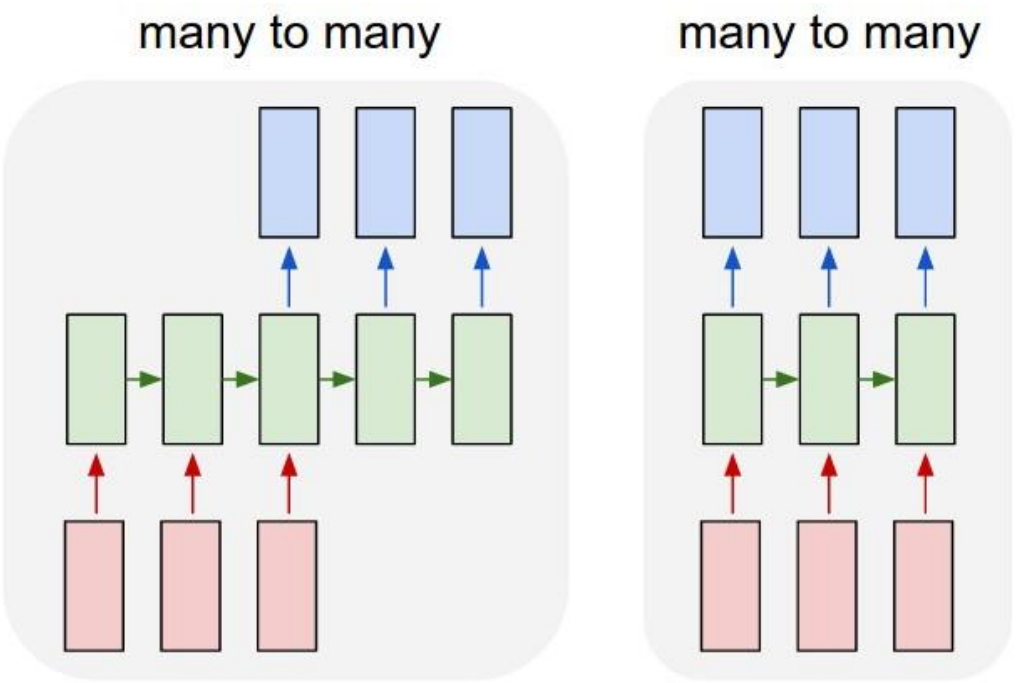

- Many-to-one در این معماری ورودی به صورت یک دنباله و خروجی به صورت یک عدد میباشد. از موارد استفاده ی این معماری میتوان به تحلیل احساسات اشاره کرد که با گرفتن یک جمله که دنباله ای از کلمات است، یک عدد در رابطه با احساس جمله ی ورودی (مثبت یا منفی بودن

آن) بازمیگرداند. از دیگر موارد استفاده این معماری که در این پروژه نیز استفاده شده به دسته بندی صوت میتوان اشاره کرد.

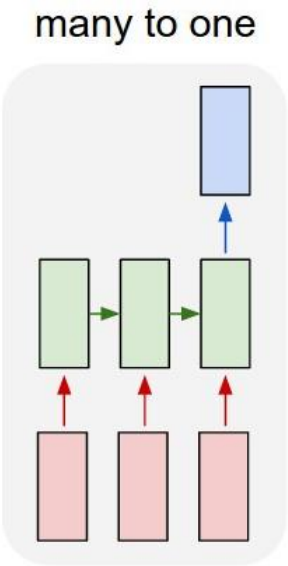

- One-to-many در این معماری ورودی به صورت یک عدد و خروجی یک دنباله میباشد. از موارد استفاده این معماری میتوان به تولید موسیقی با ورودی ژانر آن اشاره کرد.

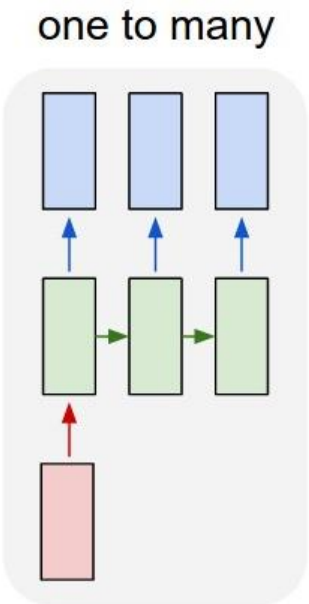

- One-to-One در این معماری هم ورودی و هم خروجی یک عدد میباشند. این معماری همانند یک شبکه عصبی مصنوعی عمل میکند.

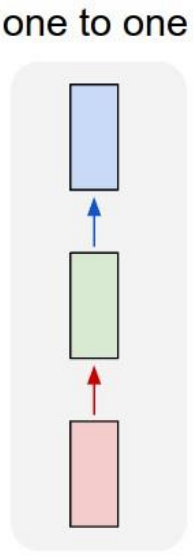

در شبکه های عصبی بازگشتی نیز هر نرون حاوی وزن ها و bias و یک تابع فعالسازی میباشد و تنها معماری آن متفاوت میباشد. در این مدل شبکه عصبی معمولا از تابع فعالسازی tanh استفاده میشود.

یک واحد ساده از شبکه عصبی بازگشتی به صورت زیر میباشد:

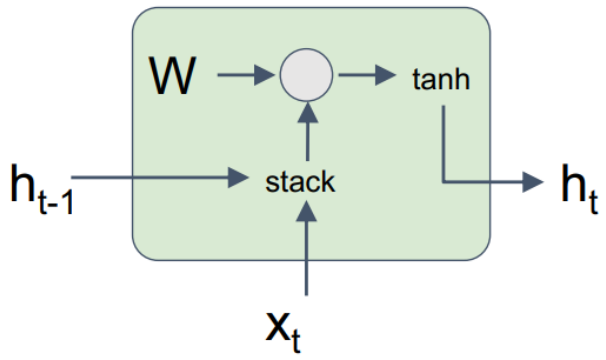

فرمول های مورد استفاده در این واحد به صورت زیر میباشد:

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

که در این فرمول W_{hh} نشان دهنده ی وزن های اعمال شده روی خروجی واحد در زمان قبلی (h_{t-1}) و W_{xh} نشان دهنده وزن های اعمال شده روی ورودی در این زمان (x_t) میباشد. در نهایت پس از اعمال وزن ها از تابع فعالسازی میگذرند و خروجی این واحد را در زمان t تشکیل میدهند.

این مدل ساده تنها از خروجی یک زمان قبل تر استفاده میکند و از مشکل محو شدگی گرادیان رنج میبرند. برای استفاده از اطلاعات زمان های قبل تر باید به این واحد حافظه اضافه کنیم. دو مدل واحد متعارف حافظه دار با نام های LSTM و GRU وجود دارند.

GRU یا Gated Recurrent Unit به استفاده از گیت ها برای نگهداری اطلاعات از گام های زمانی قبلی میباشد. در این واحد گیت های بروزرسانی و بازنشانی (Update gate و Reset gate) که مشخص میکنند چه اطلاعاتی به خروجی منتقل شوند و چه اطلاعاتی منتقل نشوند.

در تصویر زیر میتوان یک واحد GRU و فرمول های مربوط به گیت های آن را مشاهده کرد:

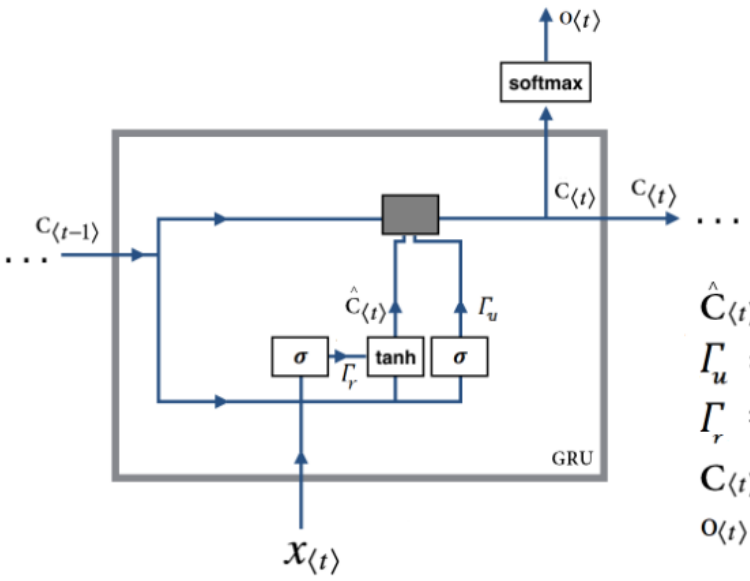

$$\hat{C}_{\langle t\rangle} = \tanh(W_1[\Gamma_r * C_{\langle t-1\rangle}, x_{\langle t\rangle}] + b_c)$$
$$\Gamma_u = \sigma(W_2[C_{\langle t-1\rangle}, x_{\langle t\rangle}] + b_u)$$
$$\Gamma_r = \sigma(W_3[C_{\langle t-1\rangle}, x_{\langle t\rangle}] + b_u)$$
$$C_{\langle t\rangle} = \Gamma_u * \hat{C}_{\langle t\rangle} + (1 - \Gamma_u) * C_{\langle t-1\rangle}$$
$$o_{\langle t\rangle} = soft\max(W_4 C_{<t>} + b_o)$$

در اینجا C همان سلول حافظه را نشان میدهد که در اصل همان h_t در واحد ساده میباشد. فرمول مربوط به گیت بروزرسانی با Γ_u نشان داده میشود و فرمول مربوط به گیت بازنشانی با Γ_r نمایش داده میشود. هر یک از این گیت ها وزن های مخصوص به خود را دارند که همگی در فرایند آموزش تنظیم میشوند.

LSTM یا Long Short Term Memory دیگر واحد حافظه دار برای شبکه های بازگشتی میباشد. این واحد هم مانند GRU با استفاده از گیت ها اطلاعات را از زمان های قبلی به خاطر میسپارد. در این واحد یک گیت جدید به نام گیت فراموشی (Forget Gate) وجود دارد که در صورت نیاز به فراموش کردن

اطلاعات قبلی منجر میشود. در تصویر زیر میتوان شکل کلی این واحد و فرمول های مربوط به آن را مشاهده کرد:

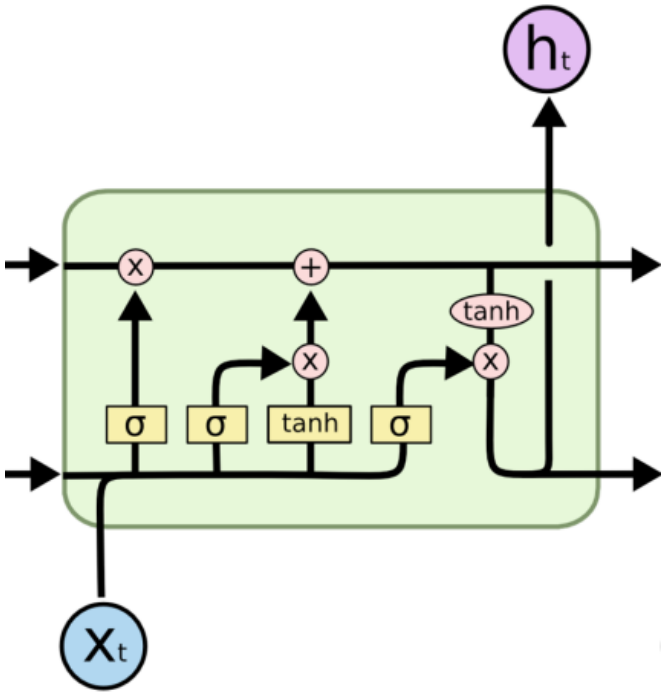

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \; + \; b_f\right)$$

$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] \; + \; b_i\right)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] \; + \; b_C)$$

$$o_t = \sigma\left(W_o \; [\, h_{t-1}, x_t] \; + \; b_o\right)$$

$$h_t = o_t * \tanh\left(C_t\right)$$

در فرمول های بالا فرمول اول مربوط به گیت فراموشی و فرمول دوم مربوط به گیت ورودی و فرمول سوم مربوط به حافظه ی داخلی و فرمول چهارم به گیت خروجی و فرمول آخر مربوط به خروجی واحد میباشد. در این پروژه از این واحد در شبکه عصبی بازگشتی استفاده شده است بدلیل ماهیت مسئله و اینکه برای تشخیص یک کلمه در یک سیگنال صوتی اطلاعات گام های زمانی قبلی در تصمیم گیری تاثیر دارند.

3-3 ابزارها

در این بخش به معرفی ابزار های مورد استفاده برای پیاده سازی این پروژه میپردازیم.

برای پیاده سازی این پروژه در تمامی برنامه ها از زبان برنامه نویسی پایتون استفاده شده است. در ادامه کتابخانه های کمکی که استفاده شده اند را معرفی میکنیم.

- **کتابخانه qtpy**: PyQtکتابخانه‌ای است که به شما امکان می‌دهد از فریمورک Qt GUI در پایتون استفاده کنید. خود Qt در C++ نوشته شده است که با استفاده از آن از طریق پایتون، می‌توانید اپلیکیشن‌ها را با سرعت بسیار بیشتری بسازیدPyQt5.به جدیدترین نسخه پنجم Qt اشاره دارد. ممکن است هنوز هم نام (Py)Qt4 را در وب بیابید، اما این نسخه دیگر قدیمی شده است و پشتیبانی نمی‌شود.

- چند نخی (multi thread) : اولین مفهومی که باید دانست process هستش، process هر برنامه ای هستش که میتونه به شکل مستقل کار کنه مثل Firefox یا Vlc. مفهوم دوم thread هستش، هر thread یک جزء کوچک از process هستش. برای multi threading در پایتون از ماژول threading استفاده میشود. باید توجه داشت که در پایتون نمیتوان multi threading را به معنای واقعی کلمه پیاده سازی کرد. پایتون توانایی اجرای دو thread در یک زمان را ندارد و فقط میتواند برنامه هایی که به شکل I/O bound هستند را مدیریت کند. در صورتی که برنامه به شکل I/O bound باشد زمانی را که صرف منتظر ماندن برای رسیدن پاسخ میکند را میتواند به کار دیگری مشغول شود. اما اگر برنامه CPU bound باشد و همواره cpu مشغول کار باشد استفاده کردن از multi threading نه تنها باعث افزایش سرعت نخواهد شد بلکه باعث افزایش فشار بروی cpu میشود و در نتیجه با کندی سرعت مواجه خواهیم شد.

در فصل های بعدی به توضیح بخش های مختلف پیاده سازی شده و توضیح کد های آنها خواهیم پرداخت.

فصل چهارم

4-1 چند نخی

Multithreading توانایی یک برنامه یا یک سیستم عامل برای فعال کردن بیش از یک کاربر در یک زمان بدون نیاز به چندین نسخه از برنامه در حال اجرا در رایانه است. Multithreading همچنین می تواند چندین درخواست از یک کاربر را مدیریت کند.

اجرای چندین رشته مشابه اجرای چندین برنامه مختلف به طور همزمان است، اما با مزایای زیر:

- چندین رشته در یک فرآیند، فضای داده مشابهی را با رشته اصلی به اشتراک می‌گذارند و بنابراین می‌توانند اطلاعات را به اشتراک بگذارند یا راحت‌تر از زمانی که فرآیندهای جداگانه باشند، با یکدیگر ارتباط برقرار کنند.

- موضوعاتی که گاهی اوقات فرآیندهای سبک وزن نامیده می شوند و به حافظه زیادی نیاز ندارند. آنها ارزان تر از فرآیندها هستند.

یک thread یک شروع، یک دنباله اجرا و یک نتیجه دارد. این یک نشانگر دستورالعمل دارد که مکان‌هایی را که در حال حاضر در زمینه‌اش اجرا می‌شود، ردیابی می‌کند.

- می توان آن را از قبل قطع کرد (وقفه)

- می توان آن را به طور موقت در حالت تعلیق قرار داد (همچنین به عنوان خواب شناخته می شود) در حالی که رشته های دیگر در حال اجرا هستند - به این حالت تسلیم می گویند.

4-2 شروع یک نخ جدید

برای ایجاد یک رشته دیگر، باید متد زیر موجود در ماژول رشته را فراخوانی می کنیم

```
thread.start_new_thread ( function, args[, kwargs] )
```

این فراخوانی روشی سریع و کارآمد را برای ایجاد موضوعات جدید در لینوکس و ویندوز امکان پذیر می کند.

فراخوانی متد فوراً برمی‌گردد و رشته فرزند شروع می‌شود و تابع را با لیست ارسال شده از آرگ‌ها فراخوانی می‌کند. هنگامی که تابع برمی گردد، رشته خاتمه می یابد.

در اینجا، args مجموعه ای از استدلال است. از یک تاپل خالی برای فراخوانی تابع بدون ارسال هیچ آرگومان استفاده کنید. kwargs یک فرهنگ لغت اختیاری از آرگومان های کلیدواژه است.

مثال

```
#!/usr/bin/python

import thread
import time

# Define a function for the thread
def print_time( threadName, delay):
   count = 0
   while count < 5:
      time.sleep(delay)
      count += 1
      print "%s: %s" % ( threadName, time.ctime(time.time()) )

# Create two threads as follows
try:
   thread.start_new_thread( print_time, ("Thread-1", 2, ) )
   thread.start_new_thread( print_time, ("Thread-2", 4, ) )
except:
   print "Error: unable to start thread"

while 1:
   pass
```

هنگامی که کد بالا اجرا می شود، نتیجه زیر را ایجاد می کند

```
Thread-1: Thu Jan 22 15:42:17 2009
Thread-1: Thu Jan 22 15:42:19 2009
Thread-2: Thu Jan 22 15:42:19 2009
Thread-1: Thu Jan 22 15:42:21 2009
Thread-2: Thu Jan 22 15:42:23 2009
Thread-1: Thu Jan 22 15:42:23 2009
Thread-1: Thu Jan 22 15:42:25 2009
Thread-2: Thu Jan 22 15:42:27 2009
Thread-2: Thu Jan 22 15:42:31 2009
Thread-2: Thu Jan 22 15:42:35 2009
```

اگرچه برای threading سطح پایین بسیار موثر است، اما ماژول thread در مقایسه با ماژول threading جدید بسیار محدود است.

4-3 ماژول Threading

ماژول threading جدیدتر همراه با 2.4Python پشتیبانی بسیار قدرتمندتر و سطح بالاتری را از thread ها نسبت به ماژول thread که در بخش قبل مورد بحث قرار گرفت، فراهم می کند.

ماژول threading تمام روش های ماژول thread را نشان می دهد و برخی روش های اضافی را ارائه می دهد -

threading.activeCount() - تعداد اشیاء رشته فعال را برمی گرداند.

threading.currentThread() - تعداد اشیاء رشته را در کنترل رشته تماس گیرنده برمی گرداند.

threading.enumerate() - لیستی از تمام اشیای رشته را که در حال حاضر فعال هستند را برمی گرداند.

علاوه بر متدها، ماژول threading دارای کلاس Thread است که threading را پیاده سازی می کند. متدهای ارائه شده توسط کلاس Thread به شرح زیر است :

run() : متد run() نقطه ورودی یک رشته است.

start() : متد start() یک رشته را با فراخوانی متد run شروع می کند.

join([time]) join() منتظر می ماند تا رشته ها خاتمه پیدا کنند.

isAlive() : متد isAlive() بررسی می کند که آیا یک رشته هنوز در حال اجرا است یا خیر.

getName() : متد getName() نام یک رشته را برمی گرداند.

setName() : متد setName() نام یک رشته را تنظیم می کند.

4-4 توضیح کد app.py

در ادامه به توضیح کد app.py میپردازیم.

```
import pyaudio
import numpy as np
from librosa import load
from librosa.feature import mfcc as mf
import time
import soundfile as sf
import tensorflow.keras as keras
import matplotlib.pyplot as plt
from threading import Thread
import os
```

ابتدا کتابخانه های مورد استفاده در این کد را به آن اضافه میکنیم.

- کتابخانه pyaudio که از آن برای دریافت ورودی از میکروفون استفاده شده است.
- تابع load از کتابخانه librosa که برای خواندن سیگنال های صوتی از فایل ها استفاده شده است.
- تابع mfcc از کتابخانه librosa که برای استخراج ضرایب mfcc از سیگنال صوتی استفاده میشود.
- کتابخانه soundfile که برای ذخیره فایل های صوتی روی سیستم استفاده شده است.
- کتابخانه keras که برای استفاده از مدل ها به آن نیاز داریم.

- کتابخانه matplotlib که برای ترسیم نمودار ها از آن استفاده میشود.
- کتابخانه threading که برای چند نخی مورد استفاده قرار گرفته است.

```
class Recorder:
    def __init__(self, sample_rate=22050, record_seconds=1):
        self.model = keras.models.load_model('rnnmodel.h5')
        self.queue = list()
        self.chunk = 1050
        self.sample_rate = sample_rate
        self.record_seconds = record_seconds
        self.p = pyaudio.PyAudio()
        self.stream = self.p.open(format=pyaudio.paFloat32,
                                  channels=1,
                                  rate=self.sample_rate,
                                  input=True,
                                  output=True,
                                  frames_per_buffer=self.chunk)
```

در این قسمت کلاس Recorder تعریف شده است که تمامی کار های برنامه که مربوط به بخش یادگیری ماشین میباشد با این کلاس است. در تصویر بالا تابع __init__ از این کلاس را مشاهده میکنید که این تابع همان تابع constructor در زبان پایتون میباشد و هر زمان ما یک نمونه جدید از این کلاس ایجاد میکنیم این تابع اجرا میشود. در این تابع مقداردهی اولیه خصوصیات نمونه را انجام میدهیم. ورودی های این تابع نرخ نمونه برداری و طول فایل های صوتی مورد استفاده در این برنامه میباشد. پس از آن دیگر مقادیر مقداردهی میشوند:

- model که مدل مورد استفاده توسط برنامه را نشان میدهد. نوع این مدل تا زمانی که ورودی و خروجی آن بصورت استاندارد باشد (ماتریسی با ابعاد 43 در 13) تفاوتی ندارد و برای این مسئله میتوان هم از شبکه cnn و شبکه rnn استفاده کرد. این مدل با استفاده از تابع load_model میتواند از فایل ذخیره شده آن، خوانده شود.
- queue که لیستی میباشد که سیگنال صوتی ورودی که از میکروفون گرفته میشود در انتهای آن اضافه میشود.
- Chunk که تعداد فریم های خوانده شده در هر بار گرفتن ورودی از میکروفون را مشخص میکند.
- Sample_rate که نرخ نمونه برداری مورد استفاده را مشخص میکند.
- Record_seconds که طول هر فایل صوتی مورد استفاده توسط مدل (به ثانیه) را مشخص میکند.
- P و stream که با استفاده از کتابخانه pyaudio برای گرفتن ورودی از میکروفون استفاده میشوند.

```
def listen(self):
    global record
    global graph
    while record:
        #print('started recording')
        # change this to button press
        '''
        if kb.is_pressed('s'):
            break
        '''
        data = self.stream.read(self.chunk , exception_on_overflow=False)
        self.queue.append(np.frombuffer(data,dtype=np.float32))
        time.sleep(0.01)
    return self.queue
```

تابع listen از این کلاس که برای ضبط صوت استفاده میشود. در ابتدا از دو متغیر global استفاده شده که برای کنترل حالات برنامه از آنها استفاده میشود. برای مثال متغیر record توسط گزینه های start recording و end recording در بخش گرافیکی برنامه کنترل میشود تا زمان شروع و پایان گرفتن ورودی از میکروفون را توسط آن مشخص کنیم. قبل از پیاده سازی و برای تست این قابلیت همانطور که در قسمت کامنت شده این تابع مشاهده میکنید، از فشردن کلید s از کیبورد برای شروع و توقف ضبط صدا استفاده میشد. اما با پیاده سازی بخش گرافیکی برنامه، با استفاده از متغیر record این موضوع کنترل میشود. برای ضبط صدا از طریق میکروفون در یک حلقه، سیگنال صوتی توسط تابع read از استریم ایجاد شده در قسمت قبلی خوانده میشود و به لیست queue اضافه میشود. این کار تا جایی که مقدار متغیر record برابر با True هست ادامه میابد.

در انتها پس از اینکه مقدار متغیر record برابر با False شد، صف سیگنال های خوانده شده بازگردانده میشود.

```
def predict(self,path=''):

    if path != '':
        widgets['record_status'][-1].setText('Status: Processing')
        data,_ = load(path)
    else:
        widgets['record_status'][-1].setText('Status: Listening')
        data = self.listen()
        data = np.array(data).flatten()
    ds = []
    # chop up the recorded audio into 1 second signals by hop size = 0.5 seconds
    for i in range(0,len(data),512):
        if i + 22050 <= len(data):
            ds.append (data[i:i+22050])
    preds = []
    for i in ds:
        mfcc = mf(y=i,sr=22050,n_mfcc=13,n_fft=2048,hop_length=512).T
        mfcc = mfcc[np.newaxis, ..., np.newaxis ]
        preds.append(np.argmax(self.model.predict(mfcc)))

    self.visualize(data,preds)
```

تابع predict که کار اصلی این کلاس را انجام میدهد. این تابع برای پیشبینی روی سیگنال های صوتی مورد استفاده قرار میگیرد. ورودی این تابع متغیر path میباشد که مقدار پیش فرض آن تهی میباشد. اگر این متغیر مقدار داشت، به این معنی میباشد که سیگنال باید از یک فایل روی سیستم خوانده شود و نه از میکروفون (این برنامه دو قابلیت دارد که یکی تشخیص کلمه کلیدی یک فایل صوتی روی سیستم و دیگری ضبط صوت و تشخیص کلمه کلیدی در آن میباشد). اگر این متغیر مقدار داشت، سیگنال صوتی که به عنوان ورودی به مدل داده میشود توسط تابع load از کتابخانه librosa خوانده میشود و در

متغیر data ذخیره میشود و وضعیت برنامه در processing قرار داده میشود. اگر متغیر ورودی تابع مقدار نداشت، وضعیت برنامه به Listening تغییر داده میشود و تابع listen از همین کلاس صدا زده میشود تا صوت ورودی ضبط شود. پس از بازگردانده شدن سیگنال صوتی توسط این تابع، مقادیر موجود در لیست بازگشتی به آرایه نامپای تبدیل میشود و در متغیر data ذخیره میشود. پس از اینکه ورودی مدل مشخص شد، ابتدا این سیگنال به سیگنال هایی به طول 1 ثانیه با گام هایی به اندازه 0.5 ثانیه تقسیم میشوند. سپس یک لیست به نام preds ایجاد شده که در این لیست کلاس پیشبینی شده برای هر قسمت از این سیگنال ذخیره میشود. در یک حلقه بر روی قسمت های یک ثانیه ای بدست آمده از سیگنال، ضرایب mfcc از سیگنال ها با استفاده از تابع mfcc از کتابخانه librosa استخراج شده و توسط تابع predict مدل، کلاس آنها تشخیص داده میشود.

در نهایت تابع visualize از همین کلاس صدا زده میشود تا خروجی برای کاربر نمایش داده شود.

```
def visualize(self,data,predictions):
    fig,ax = plt.subplots(figsize=(10,5))
    ax.set_title('Audio Signal')
    ax.set_xlabel('time')
    ax.set_ylabel('amplitude')
    ax.set_facecolor((0.01,0,0.02))
    ax.plot(np.arange(len(data)),data,color='white',lw=0.7)
    for i in range(len(predictions)):
        if predictions[i] == 1:
            y = data[i*512:i*512+22050]
            sf.write(os.getcwd()+'\\'+str(i)+'.wav',y,22050)
            x = np.arange(i*512,i*512+22050)
            if i == 0:
                ax.plot(x,y,color='green',lw=0.7)
            else:
                ax.plot(x,y,color='green',lw=0.7)

    fig.savefig(os.getcwd()+'\\1.png',dpi=500/fig.get_size_inches()[1])
```

تابع visualize برای تصویرسازی خروجی و ذخیره تصویر نمودار خروجی که برای کاربر نمایش داده میشود، پیاده سازی شده است.

ورودی این تابع سیگنال صوتی اصلی و لیست پیشبینی های انجام شده توسط مدل میباشد. ابتدا یک figure از کتابخانه matplotlib ایجاد میشود تا نمودار روی آن رسم شود. سپس نام نمودار و نام هر محور مشخص شده و رنگ پس زمینه نمودار نیز مشخص میشود. برای رسم نمودار سیگنال صوتی، ابتدا سیگنال اصلی با رنگ سفید رسم شده و برای هر بخش از سیگنال که کلمه کلیدی در آن تشخیص داده شده، با رنگ سبز روی نمودار قبلی رسم میشود. برای اینکار روی لیست predictions یک حلقه ایجاد میکنیم و اگر مقدار هر عضو از این لیست 1 بود (کلمه کلیدی در آن تشخیص داده شده بود) نمودار سبز را رسم

میکنیم. موقعیت این نمودار روی نمودار اصلی نیز توسط این موضوع که هر قسمت طولی به اندازه 1 ثانیه (22050 نمونه) و فاصله هر قسمت با قسمت های بعد و قبل آن 0.5 ثانیه (11025 نمونه) میباشد، مشخص میشود. این قسمت ها از سیگنال اصلی نیز با استفاده از تابع write از کتابخانه soundfile در همان فولدر از کد بعنوان فایل صوتی با فرمت wav. ذخیره میشود. در نهایت این نمودار در فولدر کد ذخیره میشود. دلیل اینکار هم برای تبادل اطلاعات (تصویر این نمودار) بین نخ ها میباشد. از آنجا که نمودار های کتابخانه matplotlib قابل انتقال بین نخ ها نیستند و اگر روی نخ اصلی ایجاد نشده باشند، امکان نمایش آنها وجود ندارد. برای حل این مشکل ابتدا این نمودار را بعنوان یک فایل روی سیستم ذخیره میکنیم و در زمان نمایش آن در رابط گرافیکی که روی نخ اصلی اجرا میشود، آن فایل را میخوانیم. در پیوست میتوانید تصاویری از این خروجی ها را مشاهده کنید.

```
# ------------------------------------ GUI ---------------------------------
import sys
from PyQt5.QtWidgets import QApplication, QLabel,
    QPushButton, QVBoxLayout, QWidget, QFileDialog, QGridLayout,QFileDialog
from PyQt5.QtGui import QPixmap
from PyQt5 import QtGui, QtCore
from PyQt5.QtGui import QCursor
```

در این قسمت از برنامه، رابط کاربری گرافیکی پیاده سازی شده است. ابتدا توابع و کتابخانه های مورد استفاده در این قسمت را به کد اضافه میکنیم. برای پیاده سازی رابط گرافیکی از کتابخانه PyQt5 استفاده شده که widget های مورد استفاده در این کد به آن اضافه شده است.

```
app = QApplication(sys.argv)
window = QWidget()
window.setWindowTitle('Keyword Detector')
window.setFixedWidth(1100)
window.setFixedHeight(800)
window.setStyleSheet(
    "background: #161219;"
)

grid = QGridLayout()
```

ابتدا یک نمونه اپلیکیشن گرافیکی توسط تابع QApplication از کتابخانه PyQt5 ایجاد میشود. نام برنامه، طول و عرض صفحه بازشده مقدار دهی شده است. در انتها یک grid با استفاده از تابع QGridLayout ایجاد میشود که چینش المنت های برنامه را مشخص میکند.

```
# ---------------------------- recording page ------------
def recording_frame():

    #page heading
    heading = QLabel('Recorder')
    heading.setAlignment(QtCore.Qt.AlignCenter)
    heading.setStyleSheet(
        '''
            font-size:30px;
            color:white;
            border-bottom: 1px solid white;
            padding-bottom:10px;
            font-weight:bold;
        '''
    )
    widgets['recorder_heading'].append(heading)


    # page description
    desc = QLabel('Click on "start recording" to record you
    desc.setAlignment(QtCore.Qt.AlignCenter)
    desc.setWordWrap(True)
    desc.setStyleSheet('''
        font-size:18px;
        color:white;
    ''')
    widgets['record_description'].append(desc)
```

تابع recording_frame که با اجرای آن محتویات و رابط گرافیکی را روی صفحه ایجاد شده می آورد. ابتدا یک متن بعنوان تیتر این صفحه به آن اضافه میکنیم. اینکار با استفاده از تابع QLabel انجام میگیرد. سپس با استفاده از

تابع setAlignment این المنت را به وسط صفحه می آوریم. در کتابخانه PyQt5 استایل هر المنت با سینتکسی همانند css مشخص میشود. برای مشخص کردن استایل میتوان از تابع setStyleSheet استفاده کرد. ورودی این تابع استایل مورد نظر ما برای این المنت با سینتکس css میباشد.

در ادامه متن توضیحات استفاده از برنامه اضافه میشود. اینکار نیز با اضافه کردن یک QLabel انجام میگیرد.

```
#start recording button
startbutton = QPushButton('Start Recording')
startbutton.setStyleSheet('''
    *{
    margin:10px;
    border-radius:10px;
    padding:10px;
    color:white;
    border:2px solid green;
    font-size: 16px;
    max-width:150px;
    }
    *:hover{
        background:green;
    }
''')
startbutton.setCursor(QCursor(QtCore.Qt.PointingHandCursor))
startbutton.clicked.connect(start_recording)
widgets['record_start_button'].append(startbutton)
```

در قسمت بعدی دکمه ی Start Recording که از آن برای شروع ضبط صدا استفاده میشود تعریف میشود. این المنت با استفاده از تابع QPushButton

ایجاد میشود. برای اضافه کردن یک تابع callback (که در زمانی که بر روی این دکمه کلیک شد صدا زده شود) از تابع connect استفاده شده است.

```
#stop recording button
stopbutton = QPushButton('Stop Recording')
stopbutton.setStyleSheet('''
    *{
    margin:10px;
    border-radius:10px;
    padding:10px;
    color:white;
    font-size: 16px;
    max-width:150px;
    border: 2px solid red;
    }
    *:hover{
    background:red;
    }
''')
stopbutton.setCursor(QCursor(QtCore.Qt.PointingHandCursor))
stopbutton.clicked.connect(end_loop)
widgets['record_stop_button'].append(stopbutton)
```

در ادامه نیز دکمه Stop Recording برای توقف ضبط صدا مانند قسمت قبل ایجاد میشود.

```
#select file button
button = QPushButton('Select File')
button.setStyleSheet('''
    *{
    margin:10px;
    border-radius:10px;
    padding:10px;
    color:white;
    font-size: 16px;
    max-width:150px;
    border: 2px solid white;
    }
    *:hover{
    background:white;
    color:black
    }
''')
button.setCursor(QCursor(QtCore.Qt.PointingHandCursor))
button.clicked.connect(dialog)
```

در این بخش از کد دکمه ی Select File ایجاد میشود که برای انتخاب فایل صوتی بعنوان ورودی برنامه استفاده میشود.

```
#process file button
button2 = QPushButton('Process File')
button2.setStyleSheet('''
    *{
    margin:10px;
    border-radius:10px;
    padding:10px;
    color:white;
    font-size: 16px;
    max-width:150px;
    border: 2px solid white;
    }
    *:hover{
    background:white;
    color:black
    }
''')
button2.setCursor(QCursor(QtCore.Qt.PointingHandCursor))
button2.clicked.connect(show_results)
```

در ادامه دکمه ی Process File ایجاد میشود که از آن برای پیشبینی توسط مدل و پردازش فایل صوتی استفاده میشود.

```
# recording status
stat = QLabel('Status: Waiting')
stat.setAlignment(QtCore.Qt.AlignCenter)
stat.setWordWrap(True)
stat.setStyleSheet('''
    font-size:14px;
    color:white;
    font-weight:bold;
    border: 1px solid white;
    padding:5px;
    max-width:100px;
''')
widgets['record_status'].append(stat)
```

در این قسمت یک المنت متنی که وضعیت برنامه را نشان میدهد ایجاد میشود. مقدار متن آن بصورت پیشفرض Waiting میباشد و با انجام عملیات مختلف توسط کاربر، متن آن تغییر میکند.

```
grid.addWidget(widgets['recorder_heading'][-1],0,0,1,3)
grid.addWidget(widgets['record_description'][-1],1,0,1,3)
grid.addWidget(widgets['record_start_button'][-1],2,0)
grid.addWidget(widgets['record_stop_button'][-1],2,1)
grid.addWidget(widgets['record_status'][-1],2,2)
grid.addWidget(button,3,0)
grid.addWidget(button2,3,1)
```

در انتهای تابع تمامی این بخش ها را به grid اضافه میکنیم. برای اینکار از تابع addWidget استفاده شده است که در ورودی اول خود widget و در ورودی

دوم و سوم موقعیت آن مشخص میشود. ورودی دوم تعداد سطر های این widget و ورودی سوم تعداد ستون های مورد استفاده توسط هر widget را نشان میدهد.

در ادامه به توابع callback پیاده سازی شده میپردازیم.

```
#------------------------ callback functions for gui ----

def start_recorder(path=''):
    recorder = Recorder()
    recorder.predict(path=path)
```

اولین تابع start_recorder نام دارد که برای ایجاد نمونه جدید از کلاس Recorder و پردازش سیگنال صوتی استفاده میشود.

```
def start_recording(path):
    global record
    if record:
        return
    record = True
    t1 = Thread(target=start_recorder, daemon=True)
    t1.start()
```

تابع start_recording که با فشره شدن دکمه Start Recording در رابط گرافیکی، یک نخ جدید ایجاد میشود که بر روی این نخ تابع قبلی اجرا میشود.

```
def end_loop(ispath=False):
    global record
    if record == False and ispath == False:
        return
    if record:
        record = False
    widgets['record_status'][-1].setText('Status: Waiting')
    image = 'loading'
    while True:
        if '1.png' in os.listdir():
            break
    time.sleep(0.7)
    image = QPixmap('1.png')
    plot = QLabel()
    plot.setPixmap(image)
    plot.setAlignment(QtCore.Qt.AlignCenter)
    plot.setStyleSheet('margin-top:20px;')
    grid.addWidget(plot,4,0,2,3)
    os.remove(os.getcwd()+'\\1.png')
```

تابع end_loop که با فشردن دکمه Stop Recording ضبط صدا را متوقف میکند. اینکار با قرار دادن مقدار False در متغیر record صورت میگیرد که پیش تر نحوه استفاده از آن مشخص شد. سپس وضعیت برنامه در Waiting قرار میگیرد و فایل تصویر نمودار ذخیره شده توسط تابع visualize از روی سیستم خوانده میشود و سپس با ایجاد یک المنت جدید و اضافه کردن این تصویر با استفاده از تابع QPixmap به این المنت و اضافه کردن آن به grid، خروجی به کاربر نمایش داده میشود.

```
def dialog():
    file , check = QFileDialog.getOpenFileName(None, "QFileDialog.getOpenFileName()",
                                               "", "All Files (*)")

    print(file)
    if check:
        start_recorder(file)
```

تابع dialog که با اجرای آن یک پنجره برای انتخاب فایل از روی سیستم باز شده و سپس تابع start_recorder با آدرس فایل انتخاب شده صدا زده میشود.

```
recording_frame()

window.setLayout(grid)

window.show()
sys.exit(app.exec())
```

در انتهای کد نیز تابع recording_frame را صدا میزنیم تا تمامی ویجت های برنامه به پنجره برنامه اضافه شوند و با تابع show به نمایش در بیایند.

5-4 توضیح کد real_time.py

در ادامه به توضیح کد real_time.py میپردازیم. این کد برای آشنایی بیشتر با چند نخی و نحوه استفاده از آن در این مسئله پیاده سازی شده است.

```
import pyaudio
import threading
import time
import wave
import numpy as np
from threading import Event
import tensorflow.keras as keras
import tensorflow as tf
import librosa
import soundfile as sf
```

ابتدا کتابخانه های مورد استفاده در این کد را به آن اضافه میکنیم. کتابخانه threading برای چند نخی و کتابخانه keras برای استفاده از مدل ها به کد اضافه شده اند.

```
class Listener:

    def __init__(self, sample_rate=22050, record_seconds=2):
        self.chunk = 1050
        self.sample_rate = sample_rate
        self.record_seconds = record_seconds
        self.p = pyaudio.PyAudio()
        self.stream = self.p.open(format=pyaudio.paInt16,
                                  channels=1,
                                  rate=self.sample_rate,
                                  input=True,
                                  output=True,
                                  frames_per_buffer=self.chunk)
```

در این قسمت کلاس Listener پیاده سازی شده که وظیفه آن دریافت ورودی از طریق میکروفون و ذخیره آن میباشد. ابتدا تابع __init__ برای این کلاس نوشته شده است. در این تابع پارامتر های این کلاس مقداردهی میشوند.

```
def listen(self, queue):
    while True:
        data = self.stream.read(self.chunk , exception_on_overflow=False)
        queue.append(data)
        time.sleep(0.01)
```

تابع listen برای این کلاس که ورودی را از استریم ایجاد شده برای این کلاس از میکروفون دریافت میکند و به انتهای صف اضافه میکند. این صف بعنوان ورودی به این تابع داده میشود. برای این کار از تابع read که برای استریم های ایجاد شده با کتابخانه pyaudio تعریف میشود، استفاده شده است.

```
def run(self, queue):
    thread = threading.Thread(target=self.listen, args=(queue,), daemon=True)
    thread.start()
    print("\nWake Word Engine is now listening... \n")
```

تابع run که با ایجاد یک نخ جدید، تابع listen از همین کلاس را روی این نخ اجرا میکند.

```
class WakeWordEngine:

    def __init__(self, model_file):
        self.c = 0
        self.model = keras.models.load_model('model3.h5')
        self.listener = Listener(sample_rate=22050, record_seconds=2)
        self.audio_q = list()
```

در ادامه کلاس WakeWordEngine تعریف شده است که از این کلاس برای تشخیص کلمه کلیدی استفاده میشود. ابتدا تابع __init__ را داریم که پارامترهای نمونه های این کلاس را مقداردهی میکند. ابتدا مدل این کلاس با استفاده از تابع load_model از کتابخانه keras، از فایل آن خوانده میشود. سپس یک لیست با نام audio_q ایجاد میشود که سیگنال های صوتی در آن ذخیره میشود. یک نمونه از کلاس Listener نیز برای این کلاس ایجاد میشود تا با استفاده از آن بتواند صدای محیط را از طریق میکروفون دریافت کند.

```python
def save(self, waveforms, fname="wakeword_temp"):
    wf = wave.open(fname, "wb")
    # set the channels
    wf.setnchannels(1)
    # set the sample format
    wf.setsampwidth(self.listener.p.get_sample_size(pyaudio.paInt16))
    # set the sample rate
    wf.setframerate(22050)
    # write the frames as bytes
    wf.writeframes(b"".join(waveforms))
    # close the file
    wf.close()
    return fname
```

تابع save برای این کلاس که سیگنال های صوتی دریافت شده از میکروفون را در فایلی روی سیستم ذخیره میکند تا بعدتر توسط تابع predict خوانده شوند و توسط مدل پردازش شوند. بعدتر برای برنامه اصلی از یک لیست مشترک بین نخ ها برای تبادل اطلاعات بین آنها استفاده میکنیم اما در این کد از این روش برای اشتراک اطلاعات بین چند نخ استفاده شده است که با توجه به حجم کمی که این فایل های صوتی دارند، روی سرعت کد تاثیری نمیگذارد. این ذخیره کردن سیگنال بعنوان یک فایل با استفاده از کتابخانه wave صورت گرفته است. در انتهای این تابع نام فایل ذخیره شده بازگردانده میشود.

```
def predict(self, audio):
    fname = self.save(audio)
    signal, _ = librosa.load(fname)  # don't normalize on train
    signal = signal[:22050]
    mfcc = librosa.feature.mfcc(y=signal,sr=22050,n_mfcc=13,n_fft=2048,hop_length=512).T
    mfcc = mfcc[np.newaxis, ..., np.newaxis ]

    preds = self.model.predict(mfcc)
    idx = np.argmax(preds)
    if idx == 1:
        sf.write('wavs\\'+str(self.c)+'.wav',signal,22050)
        self.c += 1
        print(str(self.c)+': ',end ='')
        print(idx)
    return idx
```

تابع predict که سیگنال صوتی خام را بعنوان ورودی دریافت کرده و با استخراج ضرایب mfcc توسط تابع mfcc از کتابخانه librosa آنرا به ورودی قابل استفاده توسط مدلها تبدیل میکند. سپس این ورودی را به مدل میدهد و با استفاده از تابع predict خروجی مدل برای این ورودی را دریافت میکند. اگر مدل کلمه کلیدی را تشخیص داده بود در کنسول 1 را چاپ کرده و اگر تشخیص نداده بود 0 چاپ میشود. در انتهای تابع کلاس پیشبینی شده توسط مدل بعنوان خروجی بازگردانده میشود.

```
def inference_loop(self, action):
    while True:
        if len(self.audio_q) > 21:  # remove part of stream
            diff = len(self.audio_q) - 21
            for _ in range(diff):
                self.audio_q.pop(0)
            self.predict(self.audio_q)
        elif len(self.audio_q) == 21:
            self.predict(self.audio_q)
        time.sleep(0.05)
```

تابع inference_loop که یک حلقه بینهایت میباشد و با دریافت ورودی از میکروفون، مدام تابع predict را بر روی صوت ورودی اجرا میکند.

6-4 مزایای Multithreading در پایتون

مزایای ایجاد یک برنامه چند رشته ای در پایتون به شرح زیر است:

- استفاده موثر از منابع سیستم کامپیوتری را تضمین می کند.
- برنامه های چند رشته ای پاسخگوتر هستند.
- این منابع و وضعیت خود را با موضوعات فرعی (فرزند) به اشتراک می گذارد که آن را اقتصادی تر می کند.
- به دلیل شباهت، معماری چند پردازنده را موثرتر می کند.
- با اجرای همزمان چندین رشته در زمان صرفه جویی می کند.
- سیستم برای ذخیره چندین رشته به حافظه زیادی نیاز ندارد.

فصل پنجم

5-1 ارائه معماری برای مدل ها

در این قسمت به جزئیات و معماری مدل ها میپردازیم. برای شروع کار از یک معماری معمول و متداول برای شبکه ها استفاده کردیم که جلوتر به جزئیات آن اشاره میشود. سپس به بررسی عملکرد مدل ها میپردازیم و در نهایت راه حل های استفاده شده برای بهبود عملکرد مدل را بررسی میکنیم.

5-1-1 مدل RNN

مدل‌سازی و پیش‌بینی داده‌های متوالی نیازمند رویکردی متفاوت از رگرسیون یا طبقه‌بندی استاندارد است. خوشبختانه، نوع خاصی از شبکه های عصبی به نام شبکه های عصبی بازگشتی (RNN) به طور خاص برای این منظور طراحی شده اند.

در این مقاله به ساختار RNN ها می پردازم و یک مثال کامل از نحوه ساخت یک RNN ساده با استفاده از Keras و Tensorflow در پایتون به شما ارائه می کنم.

2-5 نگاهی به جهان یادگیری ماشین

در حالی که شبکه‌های عصبی اغلب به شیوه‌ای تحت نظارت با داده‌های آموزشی برچسب‌گذاری شده استفاده می‌شوند، من احساس کردم که رویکرد منحصربه‌فرد آنها به یادگیری ماشینی مستحق یک دسته جداگانه است. شبکه های عصبی مکرر زیرشاخه خود را دارند که از RNN های ساده، LSTM (حافظه کوتاه مدت بلندمدت) و GRU (واحد بازگشتی دردار) تشکیل شده است.

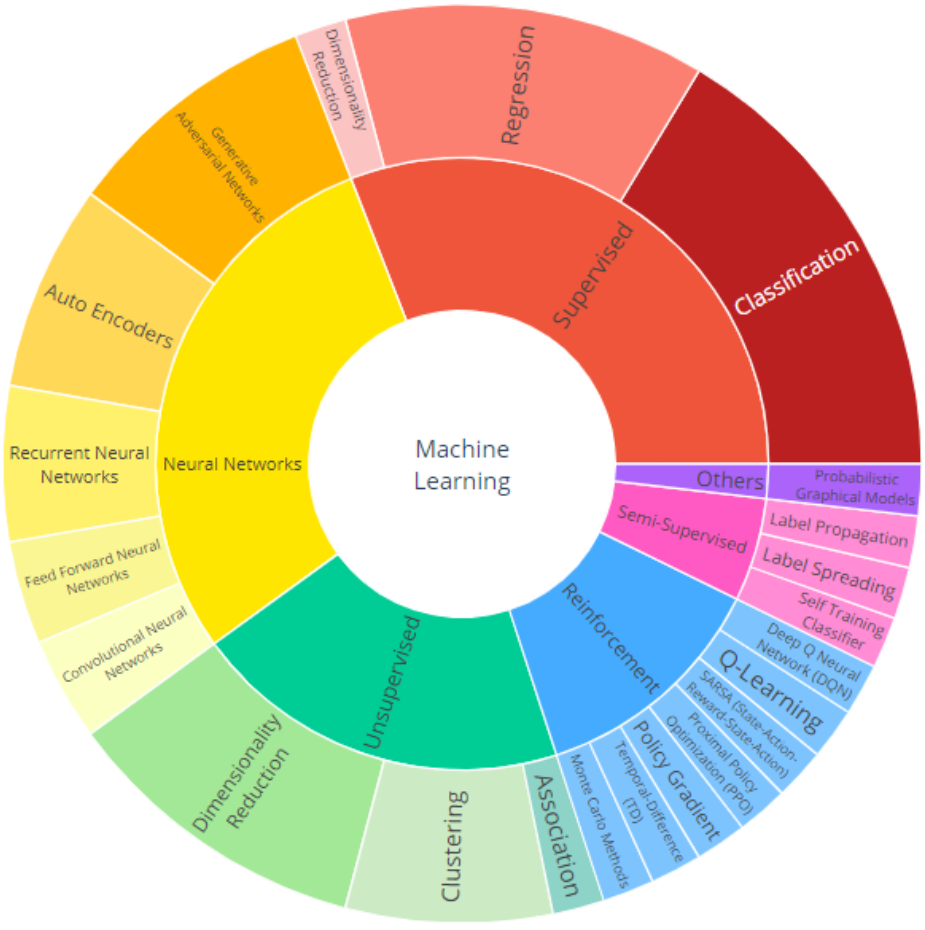

3-5 ساختار شبکه های عصبی بازگشتی (RNN)

ابتدا، بیایید به خود یادآوری کنیم که یک شبکه عصبی فید فوروارد معمولی چگونه است. توجه داشته باشید که می تواند شامل هر تعداد گره ورودی، گره پنهان و گره خروجی باشد. ساختار 2-3-2 زیر صرفاً برای مثال است.

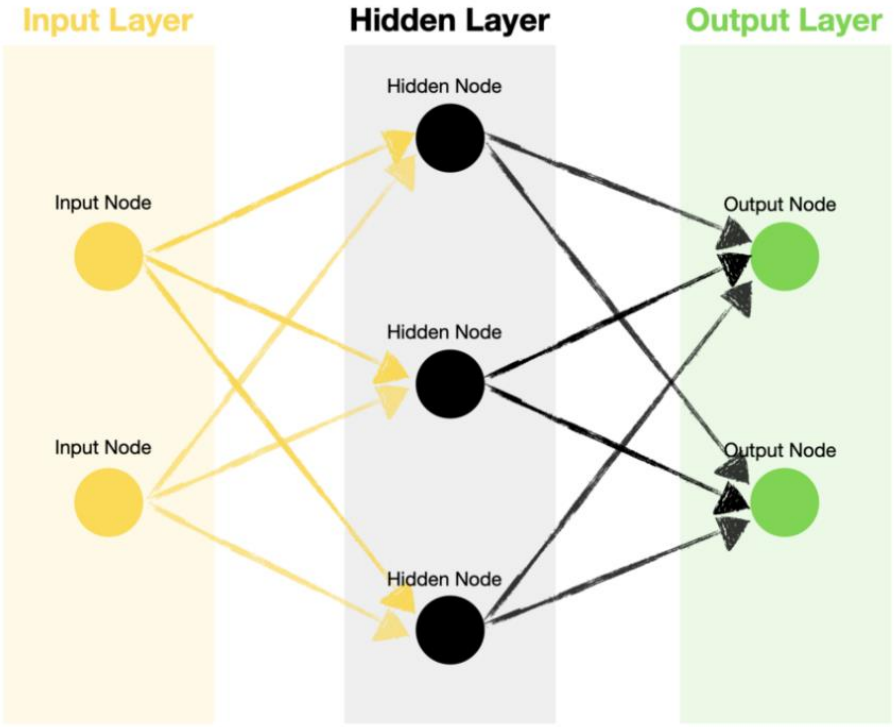

در مرحله بعد، اگر به RNN نگاه کنیم، متوجه تفاوت جزئی می شویم. واحدهای پنهان در داخل RNN دارای یک حلقه بازخورد داخلی هستند که اطلاعات را قادر می سازد چندین بار به یک گره بازگردانده شود. این واحدهای پنهان معمولاً واحدهای مکرر نامیده می شوند.

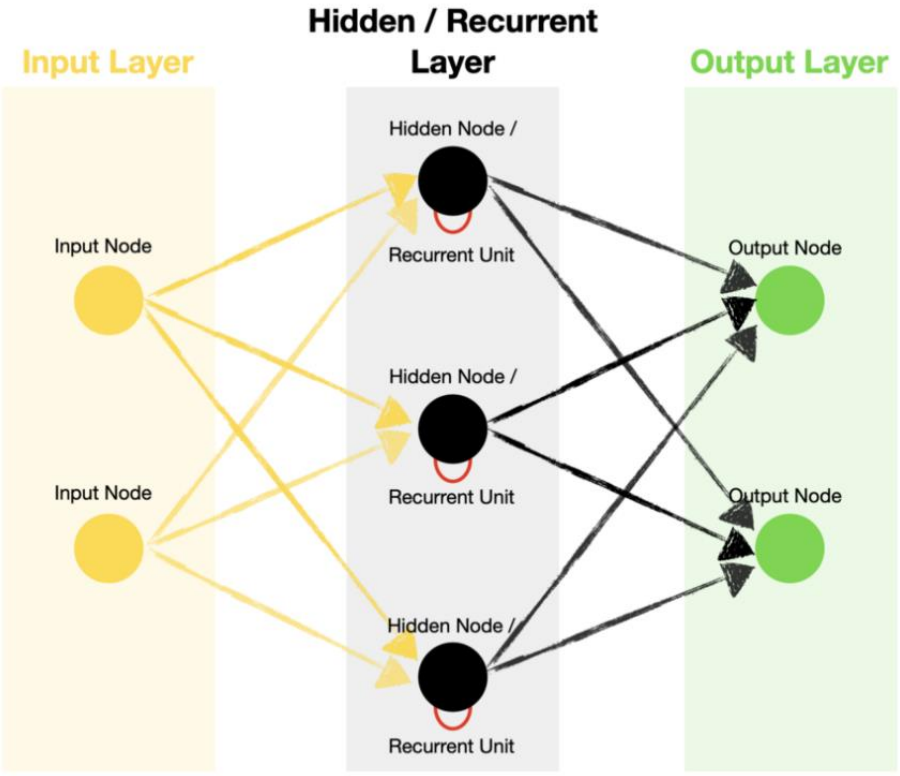

تصویر زیر را ببینید که حلقه بازخورد داخل واحد برگشتی را نشان می دهد:

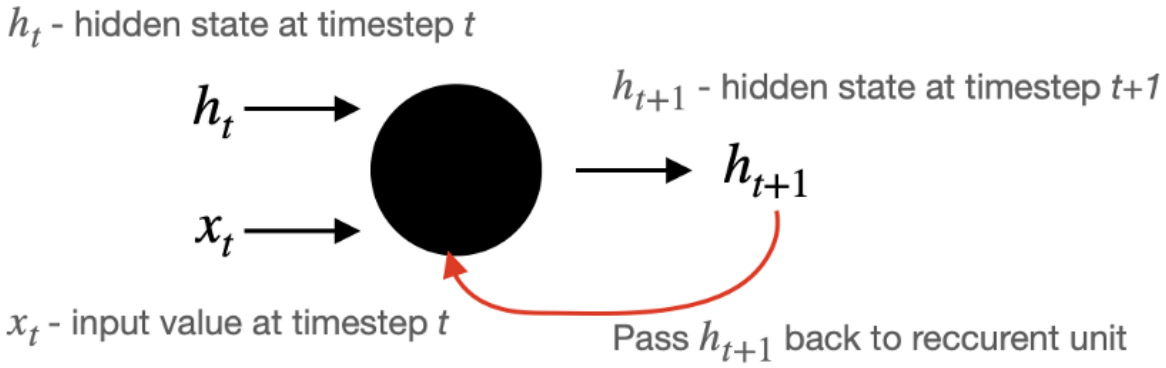

توجه داشته باشید که در مرحله زمانی اولیه، حالت پنهان h0 به 0 مقداردهی اولیه می شود. سپس خروجی (یک حالت پنهان h در t+1) به یک واحد بازگشتی ارسال می شود و دوباره همراه با ورودی زیر پردازش می شود:

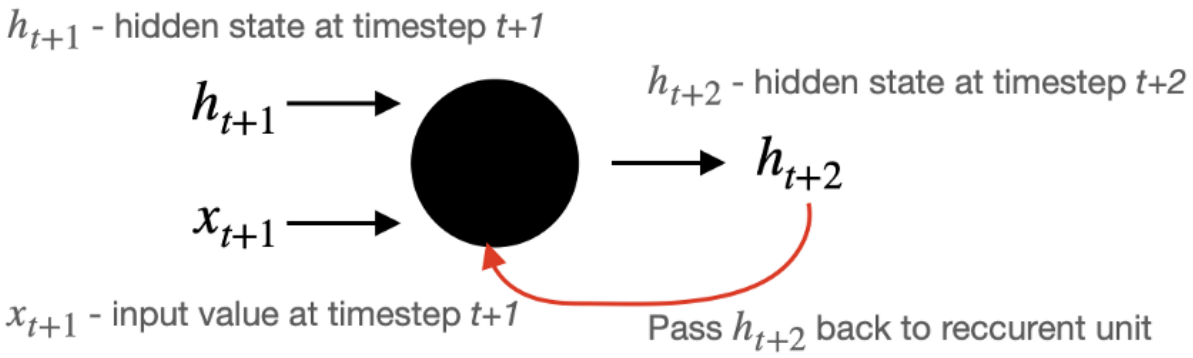

این فرآیند تا رسیدن به تعداد زمان مشخص شده تکرار می شود.

بیایید همه آن را به هم گره بزنیم و ببینیم یک RNN ساده با یک ورودی، یک گره پنهان (شامل سه مرحله زمانی) و یک خروجی چگونه خواهد بود.

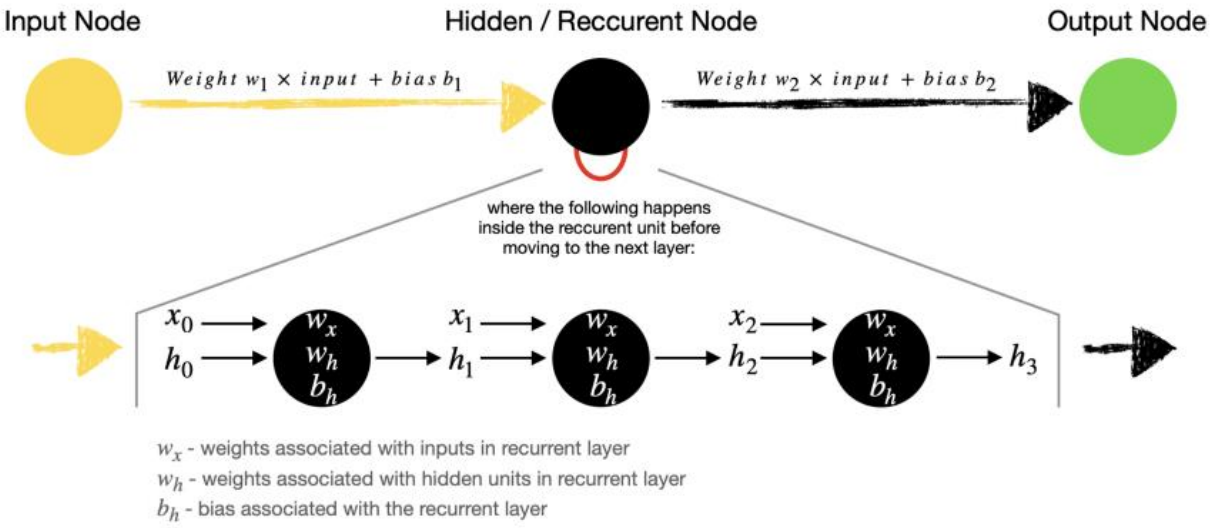

4-5 توضیح کد model.py

در این قسمت به توضیح کد model.py و معماری ارائه شده برای مدل بازگشتی میپردازیم.

در تصویر زیر لایه های این مدل و اطلاعات آنها آورده شده است.

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
lstm (LSTM)                  (None, 45)                10620
_________________________________________________________________
dense (Dense)                (None, 32)                1472
_________________________________________________________________
dropout (Dropout)            (None, 32)                0
_________________________________________________________________
dense_1 (Dense)              (None, 2)                 66
=================================================================
Total params: 12,158
Trainable params: 12,158
Non-trainable params: 0
```

ابتدا یک لایه Lstm با 45 واحد در ابتدای مدل قرار میگیرد. سپس خروجی این لایه به یک لایه ی fully connected با 32 نرون داده میشود که این لایه با یک لایه dropout دنبال میشود تا از overfit شدن مدل جلوگیری کند. در انتها نیز لایه ی خروجی با دو نرون وجود دارد. معماری این مدل برای جلوگیری از overfit شدن مدل، ساده تر شده است که در قسمت های بعدی به این موضوع میپردازیم.

در ادامه توضیحات کد model.py را خواهیم داشت.

```
import json
import numpy as np
from sklearn.model_selection import train_test_split
import tensorflow.keras as keras
import pandas as pd
```

ابتدا کتابخانه های مورد استفاده در این کد را اضافه میکنیم. کتابخانه ی json که برای خواندن دیتاست ها استفاده میشود. کتابخانه keras که برای ایجاد مدل ها و آموزش آنها مورد استفاده قرار میگیرد.

```
# RNN-LSTM model
input_shape = (X_train.shape[1], X_train.shape[2])  # ( # of segments, # of coefs
learning_rate = 0.0001
```

در این قسمت از کد پارامتر های مورد استفاده برای مدل را مقدار دهی میکنیم. ابعاد ورودی شبکه عصبی که در متغیر input_shape ذخیره شده است، با استفاده از مقادیر shape که ابعاد یک ماتریس از کتابخانه numpy را در خود نگه میدارد، مقدار دهی شده است. برای شبکه های عصبی بازگشتی ابعاد ورودی باید به صورت زیر باشد:

[number of time steps, number of features]

که در مسئله ی ما تعداد time step ها همان تعداد قسمت های هر سیگنال صوتی میباشد و تعداد ویژگی ها نیز همان تعداد ضرایب استخراج شده از هر سیگنال میباشد.

```
model = keras.Sequential()
```

ابتدا با استفاده از تابع Sequential از کتابخانه keras یک مدل پایه ایجاد میکنیم. این مدل در ابتدا هیچ لایه ای ندارد اما با استفاده از تابع add از همین کتابخانه میتوان به آن به ترتیب لایه اضافه کرد.

```
model.add(keras.layers.LSTM(45, input_shape=input_shape))
```

با استفاده از تابع add یک لایه ی LSTM با 45 واحد به مدل اضافه میکنیم. برای ایجاد این لایه از ماژول layers در کتابخانه keras استفاده شده است که در این ماژول انواع لایه های شبکه های عصبی وجود دارد. این لایه بصورت many to one میباشد چراکه تنها خروجی آخرین واحد از این لایه به لایه بعدی داده میشود. این لایه یک ورودی دیگر علاوه بر تعداد واحد ها به نام input_shape دارد که ابعاد ورودی لایه را مشخص میکند (به این خاطر که این لایه اولین لایه در مدل میباشد نیاز هست تا این مقدار برای آن مشخص شود. ابعاد ورودی برای لایه های بعدی با توجه به ابعاد خروجی لایه قبلیشان، مشخص میشود)

```
model.add(keras.layers.Dense(32,activation='relu'))
model.add(keras.layers.Dropout(0.35))
```

بعد از لایه LSTM یک لایه fully connected با 32 نرون و به دنبال آن یک لایه dropout اضافه شده است. تابع فعالسازی برای لایه fully connected برابر با relu قرار داده شده و پارامتر ورودی برای لایه dropout که احتمال

غیرفعالسازی هر نرون در هر تکرار را نشان میدهد برابر با 0.35 قرار داده شده است.

```
#softmax
model.add(keras.layers.Dense(2,activation='softmax'))
```

در انتها لایه خروجی که یک لایه fully connected با 2 نرون میباشد به مدل اضافه شده است. تابع فعالسازی این لایه به دلیل اینکه یک احتمال برای هر کلاس میخواهیم، softmax در نظر گرفته شده است.

```
#compile
optimiser = keras.optimizers.Adam(learning_rate)
model.compile(optimizer = optimiser, loss='sparse_categorical_crossentropy',metrics=['accuracy'])
```

در این قسمت الگوریتم بهینه سازی مدل برابر با الگوریتم Adam optimizer قرار داده شده است. برای نهایی سازی مدل و مقداردهی پارامتر های آن از تابع compile مدل میتوان استفاده کرد. برای این تابع الگوریتم بهینه سازی و تابع ضرر مشخص شده است. تابع ضرر برای این مسئله sparse categorical cross entropy در نظر گرفته شده که همان تابع cross entropy میباشد که در مسائل کلاس بندی کاربرد دارد.

```
#********** train the model
model.fit(X_train, Y_train, epochs = 15, batch_size = 32, validation_data = (X_val,Y_val))

loss = pd.DataFrame(model.history.history)
loss.plot()
```

سپس مدل با تابع fit آموزش داده میشود. ورودی اول و دوم این تابع دیتاست های آموزش میباشد. ورودی epoch تعداد تکرار بر روی کل دیتاست را

مشخص میکند که برابر با 15 قرار داده شده است. ورودی batch_size تعداد اعضای هر mini batch در الگوریتم mini batch stochastic gradient descent (به صورت پیش فرض از این الگوریتم برای بهینه سازی در مدل های Sequential کتابخانه keras استفاده میشود) را مشخص میکند که برابر با 32 قرار داده شده است. در آخرین ورودی این تابع نیز دیتاست های validation مقداردهی شده اند. در خط بعدی مقدار خطا در هر تکرار را از مدل استخراج میکنیم و آن را بصورت یک جدول با استفاده از تابع DataFrame از کتابخانه pandas ذخیره میکنیم. در خط بعد با استفاده از تابع plot موجود برای DataFrame ها، نمودار خطا در طول زمان را رسم میکنیم.

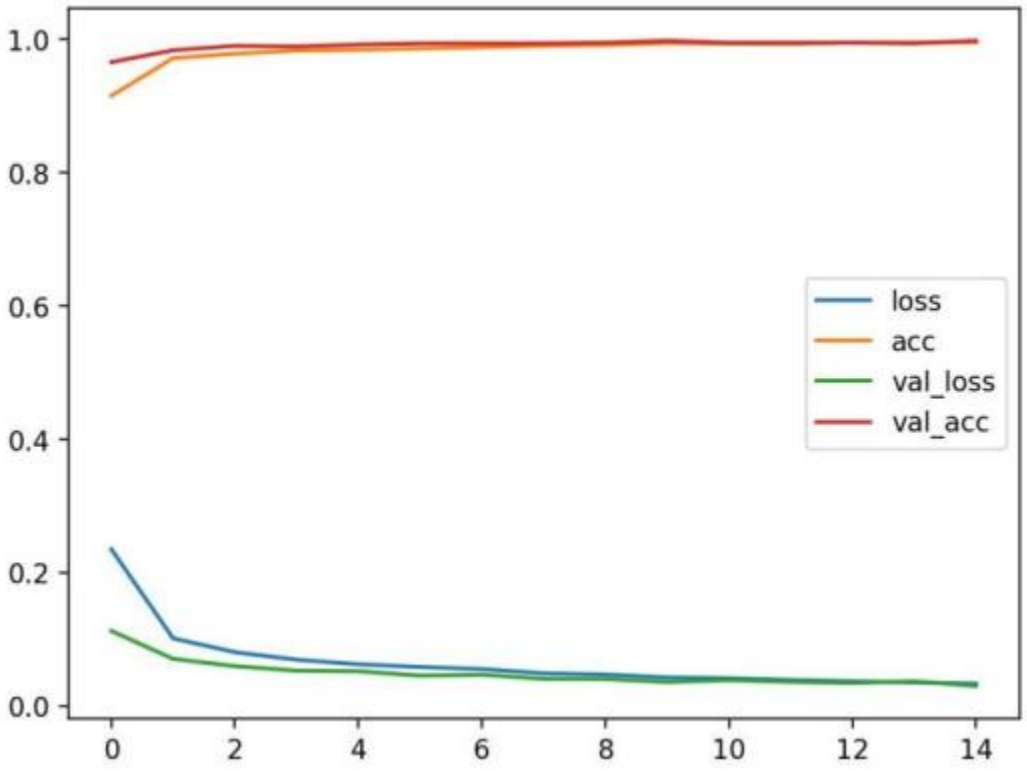

در نمودار بالا میتوان تغییرات خطا در هر تکرار را برای داده های آموزش و داده های validation مشاهده کرد.

```
#save model
model.save(path+'//rnnmodel.h5')
```

در نهایت مدل را با فرمت h5 با استفاده از تابع save ذخیره میکنیم.

فصل ششم

6-1 خلاصه

به طور کلی این پروژه به دو بخش یادگیری ماشین و طراحی و پیاده سازی برنامه دسکتاپ تقسیم شده بود که بخش طراحی و پیاده سازی برنامه دسکتاپ پروژه بر عهده اینجانب بود.

کار های انجام شده در بخش پیاده سازی برنامه دسکتاپ به همان صورت که در فصول قبل آورده شده بود می باشد و شامل مراحل مختلف از جمله پیاده سازی کد app.py برای طراحی رابط کاربری گرافیکی در فصل 4 ، کد real_time.py برای گرفتن صوت از ورودی میکروفون در حین اجرا و رسم نمودار و سپس فرستادن یک یک ثانیه ی صوت به model.py در فصل 4 و کد model.py برای ساخت مدل ها به منظور train کردن آنها که در فصل 5 آورده شده بود.

6-2 نتیجه گیری

شکی نیست که دستیارهای صوتی شاهکار بزرگی از نبوغ بشر هستند و خواهند شد و در حال حاضر به شکل یا شکلی وارد زندگی ما شده اند. با عرضه نهایی اینترنت 5G و بهبود دستیارهای صوتی یادگیری ماشینی ممکن است خود را به عنوان ابزاری تبدیل کنند که نمی توانیم بدون آن زندگی کنیم.

با این حال، قبل از رسیدن به آن مرحله، موانعی برای عبور وجود دارد که شامل سرمایه گذاری سنگین، بهبود فناوری و اعتماد مصرف کنندگان به این است که این دستگاه که در زندگی آنها است خطری برای حریم خصوصی آنها ندارد.

مراجع

[1] Hendrik Purwins, Bo Li, Tuomas Virtanen, Jan Schlüter, Shuoyiin Chang, Tara Sainath. Deep Learning for Audio Signal Processing.

[2] Nal Kalchbrenner, Erich Elsen, Karen Simonyan, Seb Noury, Norman Casagrande, Edward Lockhart, Florian Stimberg, Aaron van den Oord, Sander Dieleman, Koray kavukeuoglu. Efficient Neural Audio Synthesis

[3] Yefei Chen, Heinrich Dinkel, Mengyue Wu, Kai Yu. Voice activity detection in the wild via weakly supervised sound event detection

[4] Dario Amodei, Rishita Anubhai, Eric Battenberg, Carl Case, Jared Casper, Bryan Catanzaro, Jingdong Chen, Mike Chrzanowski, Adam Coates, Greg Diamos, Erich Elsen, Jesse Engel, Linxi Fan, Christopher Fougner, Tony Han, Awni Hannun, Billy Jun, Patrick LeGresley, Libby Lin, Sharan Narang, Andrew Ng, Sherjil Ozair, Ryan Prenger, Jonathan Raiman, Sanjeev Satheesh, David Seetapun, Shubho Sengupta, Yi Wang, Zhiqian Wang, Chong Wang, Bo Xiao, Dani Yogatama, Jun Zhan, Zhenyao Zhu. Deep Speech 2: End-to-End Speech Recognition in English and Mandarin

[5] Yun-Chia Liang, Iven Wijaya, Ming-Tao Yang, Josue Rodolfo Cuevas Juarez, Hou-Tai Chang. Deep Learning for Infant Cry Recognition

[6] Francois Chollet. Deep Learning with Python

پیوست

نحوه کار با برنامه دسکتاپ

ابتدا کد app.py را اجرا میکنیم تا رابط کاربری گرافیکی نمایش داده شود.

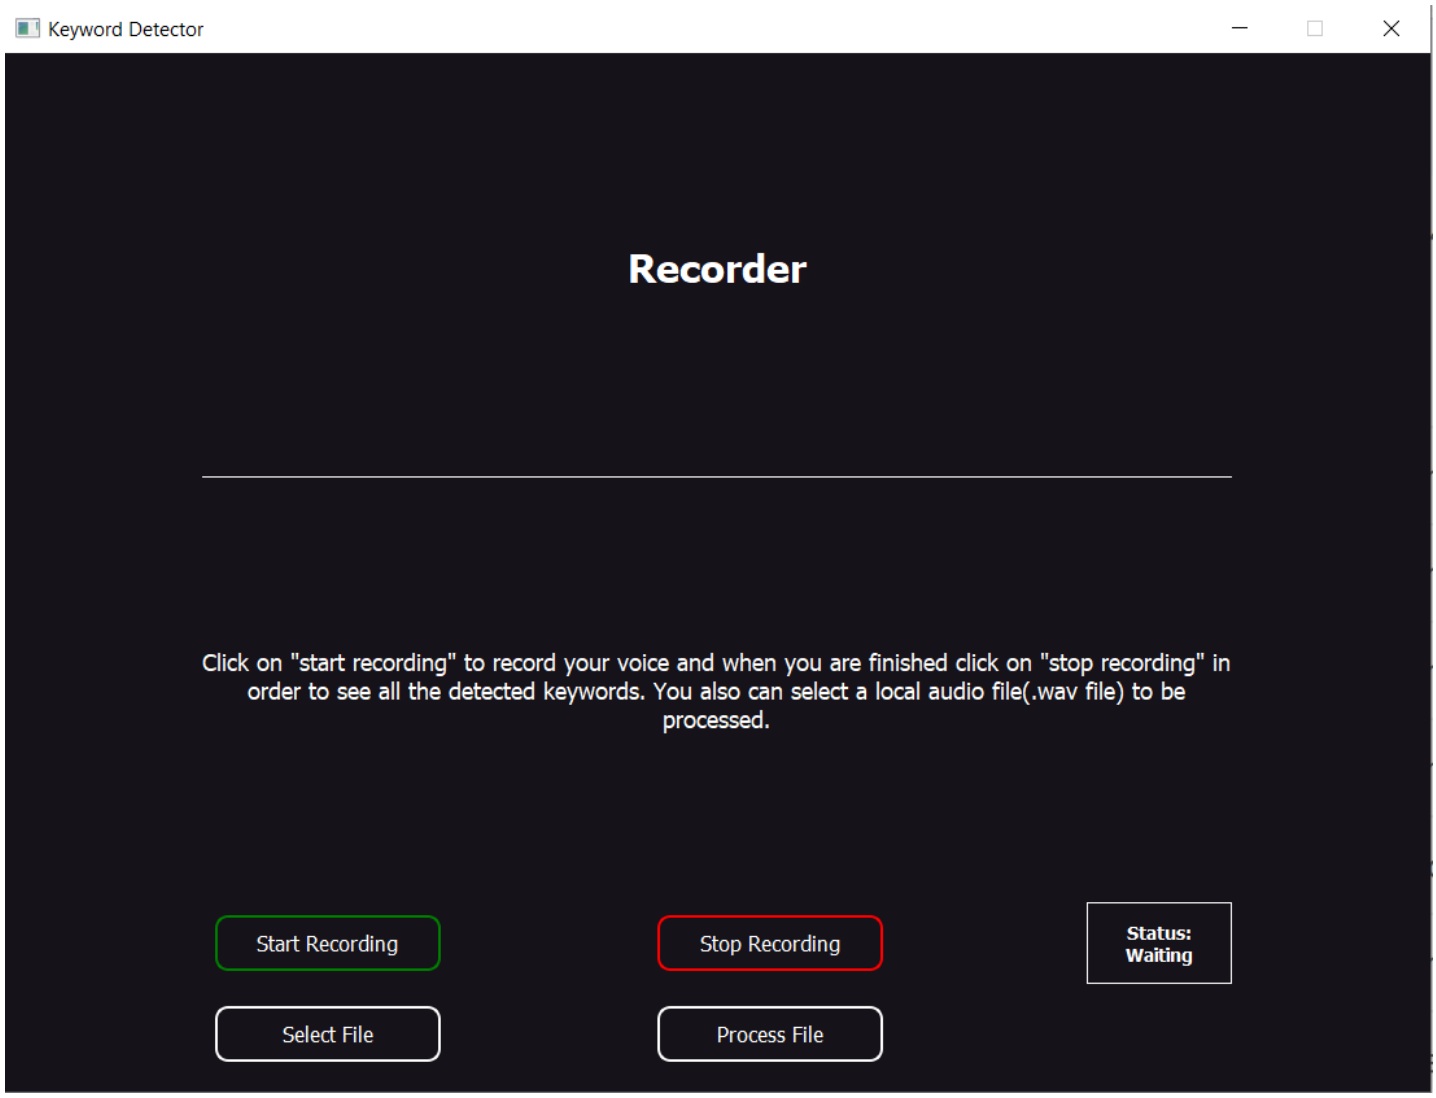

برای استفاده از قابلیت تشخیص صوت در صوت ضبط شده ابتدا بر روی دکمه Start Recording کلیک میکنیم و زمانی که status به Listening تبدیل شد به این معنی است که برنامه در حال دریافت صدا از میکروفون میباشد. هر زمان که خواستیم تا ضبط متوقف شود بر روی Stop Recording کلیک میکنیم و منتظر خروجی برنامه میمانیم. خروجی برنامه به صورت تصویر زیر به نمایش گذاشته میشود:

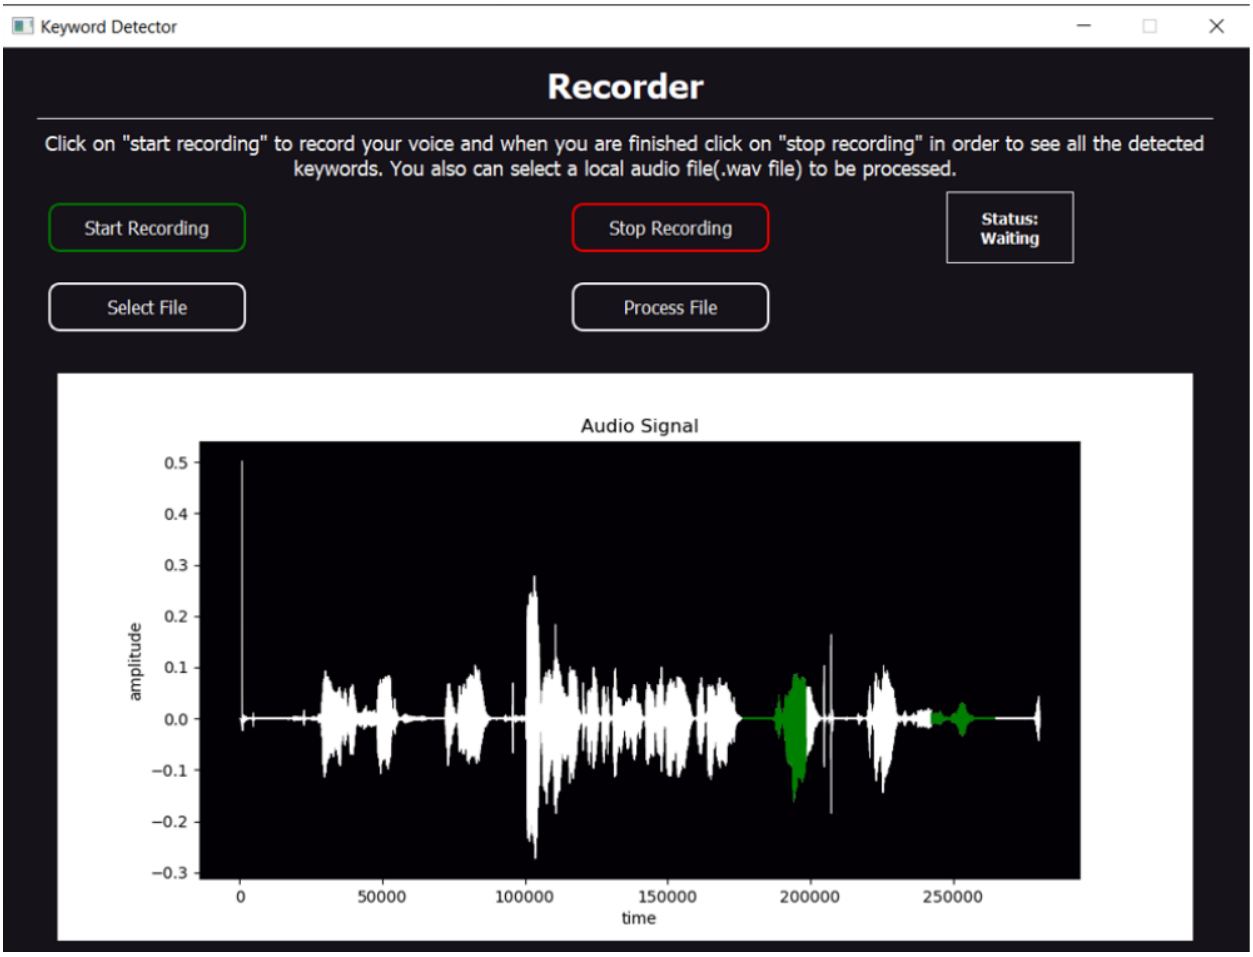

که در آن سیگنال صوت ضبط شده نمایش داده میشود و قسمت های سبز نشان دهنده ی بخش هایی از صوت است که برنامه کلمه کلیدی را تشخیص داده

است. همچنین در فولدری با نام detected فایل های صوتی 1 ثانیه ای از بخش هایی که کلمه کلیدی تشخیص داده شده قرار میگیرد.

برای استفاده از قابلیت انجام پردازش بر روی یک فایل داخل سیستم خود، روی Select File کلیک میکنیم و فایل مورد نظر خود را انتخاب میکنیم. زمانی که status به Processing تبدیل شد بر روی Process File کلیک کرده تا پردازش روی فایل صورت بگیرد و خروجی نمایش داده شود. خروجی این بخش هم مانند بخش قبل میباشد.

در تصویر زیر قسمت انتخاب فایل برای این قابلیت را مشاهده میکنید:

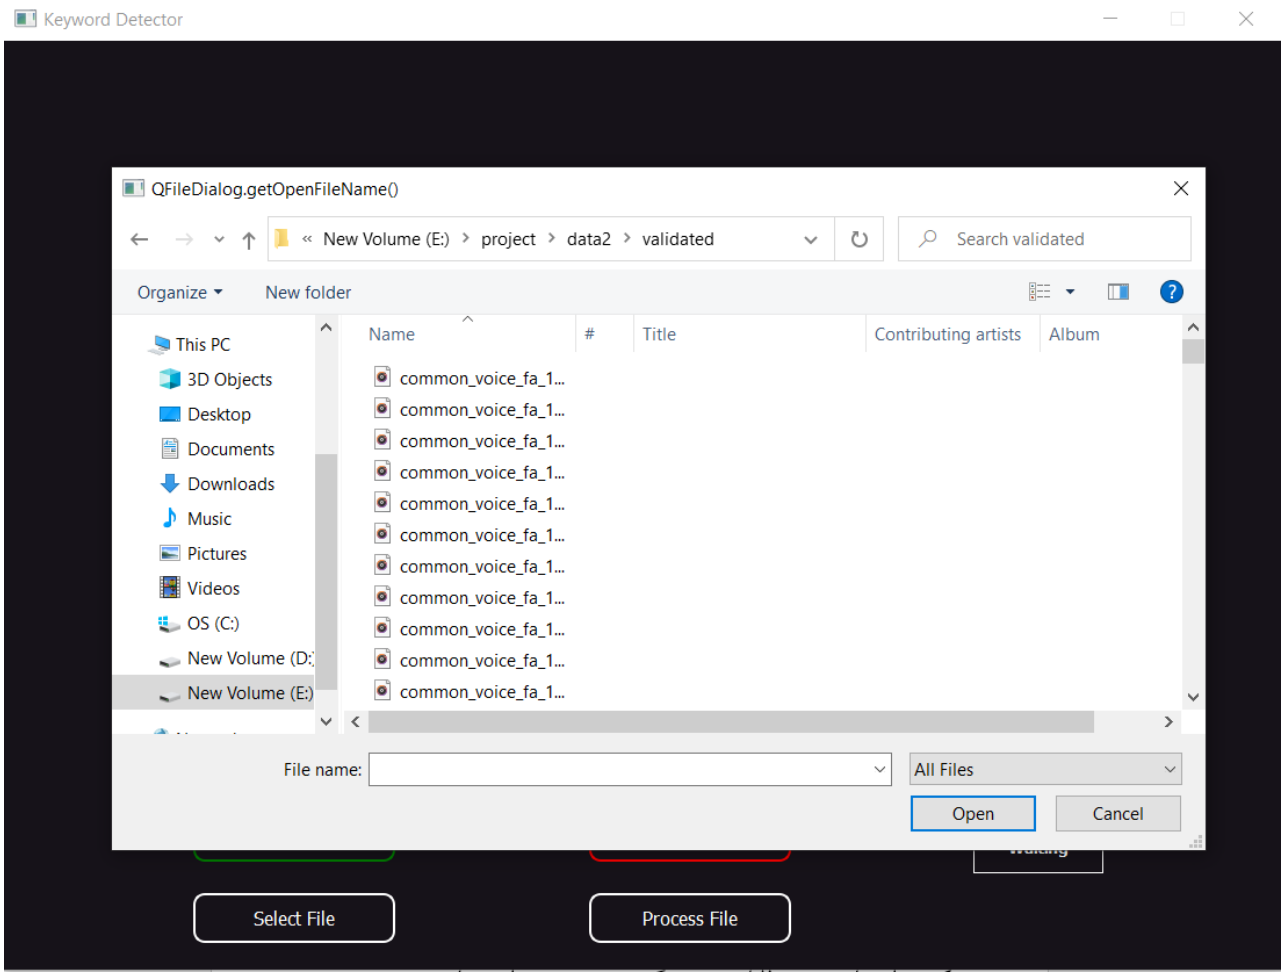

University of Tehran

College of Farabi

Faculty of Engineering

Department of Computer Engineering

Implementation of a Persian Speech Recognition System using deep learning methods

By:

Seyyed Sina Mousavi Sabet

Under Supervision of:

Dr. Zahra Movahedi

A Project Report as a Requirement for the Degree of Bachelor of Science in Computer Engineering

September 2022